

面向机器人中医舌诊采集的置信度感知边缘路由： Edge-IQA 与 LangGraph 闭环采集

匿名作者

Abstract

中医远程舌诊的机器人舌象采集需要在运动控制、端侧质量评估与上云策略之间紧密协同，并适应变化的网络时延。本文提出云-边-端架构，将学习型感知移出 1kHz 的 ROS 控制回路：轻量级 *Edge-IQA* 在网关上为每帧打分，*LangGraph* 路由器在有限重试预算 K 内决策上云、边缘重采或 fail-safe 中止。在 ShezhenV3-COCO 测试集（553 张，真实 Edge-IQA 分数，500 帧 $\times$ 3 种子，B0-B3）上，B2 相对 B0 将 RTT 中位数（M1 p50）从 383.6 ms 降至 341.2 ms，有效帧率（M2）从 0.52 提升至 1.00。Edge-IQA 在 572 对验证样本上标定 $\tau=0.498$ ，CPU p95 约 9.6 ms。Franka 辅轨闭环（50 trial）证实路由决策可在执行栈上复现。

1 引言

中医远程舌诊需要机械臂载相机可重复地采集高质量舌象，方可支撑云端分析与电子病历（EMR）集成 [6, 8]。临床舌诊依赖颜色、纹理、苔质与形态等特征，在微动模糊、光照不均与拍摄距离失当时显著退化 [8]。朴素流水线将每帧上传云端，既浪费带宽，又在链路较慢时放大端到端时延。

动机。 云边协同机器人可将重型视觉模型卸载至云端，同时保持采集闭环响应性。但在中医成像中 *GIGO* 效应尤为突出：一次模糊上传即浪费 RTT，并可能将低置信特征传入下游分类器。边侧质量门控因此须满足：(i) 足够快以嵌入闭环；(ii) 可解释、可审计；(iii) 能在真实舌象语料上标定，而非仅依赖合成占位数据。

方法概述。 本文研究 Franka Research 3 (FR3) 平台上的云-边-端架构，采用 ROS 2 与 MoveIt。感知与路由策略位于 Python 边侧网关 (*franka_api_server*) 与 *doctor/paper1* 研究树，不嵌入硬件插件，便于无机器人环境测试。轻量 *Edge-IQA* 融合 Laplacian 清晰度与曝光为 $Q_{\text{img}} \in [0, 1]$ ；*LangGraph* 路由器在重试预算 K 内决策 *upload_cloud*、*resample_edge* 或 *fail_safe*。

全量数据集评估。 阶段 2 合成原型之后，我们在公开 *ShezhenV3-COCO* (6,719 张) 上验证：在 572 对验证样本（清晰 + 合成模糊）上标定 τ ，主矩阵对 553 张测试图像使用真实 Edge-IQA 分数，每 seed 500 帧。

贡献。

1. **Edge-IQA**：融合 Laplacian 清晰度与曝光的 $O(HW)$ 指标，在 ShezhenV3 验证集标定 $\tau^*=0.498$ ，512 px 下 CPU p95 低于 10 ms。
2. **LangGraph 置信度感知路由**：三支策略 (*upload_cloud*、*resample_edge*、*fail_safe*)， $K=2$ ，JSONL 可复现日志。
3. **双轨评估**：真实 TCM 测试分数上 B0-B3 提供表 9；Franka 辅轨 (M6) 验证执行栈趋势，CSV 不与主表混用。

章节安排。 第 2 节综述相关工作；第 3 节给出系统、Edge-IQA、路由与闭环协议；第 5 节描述 ShezhenV3 队列、标定与主实验；第 8 节总结与展望。

2 相关工作

机器人医学成像。 手术与诊断机器人广泛采用 ROS 2 与 MoveIt [1, 4]。遥操作与自主相机须满足关节限位、避障与 repeatable 视点，故采用 *skills*（标定位姿）而非临时关节遥操作。本文以 *go_to_tongue_pose*、*go_to_face_pose* 等具名 skill 替代在线阻抗调参，满足临床可重复性且与力控研究线程解耦。

图像质量评估。 全参考指标 (PSNR、SSIM) 需 pristine 参考图，不适用于逐患者采集。**手工 NR-IQA** (Laplacian、BRISQUE、NIQE 等) 无需参考图 [5]，但在路由前常需额外分数映射，且难提供 blur/曝光语义供临床审计。**深度 NR-IQA** (DB-CNN [7]、NIMA、HyperIQA 等) 在 benchmark 上感知相关性强，但依赖 GPU、模型版本管理与黑盒解释。

边侧闭环机器人偏好线性复杂度、可审计失效模式；本文 Edge-IQA 显式输出 blur/曝光标志并以 τ 驱动 LangGraph (表 2)。本文不追求通用 MOS 排行榜冠军，而追求 TCM 舌象上 CPU 延迟与可复现约束下的**边侧采集门控**。

边云协同。 分流推理与早退策略降低移动视觉带宽 [2,3]。Neurosurgeon 类框架按层切分 DNN；本文则在重型云模型运行前，以轻量打分器门控上传决策。LangGraph 式状态机可表达可审计分支，优于嵌入 if-else 且无结构化轨迹导出的单体 ROS 节点。

中医舌象分析。 云端舌象分类、分割与颜色分析已较成熟 [6,8]。ShezhenV3-COCO 等公开语料提供框标注与类别标签，服务下游诊断模型。Paper I 聚焦这些模型上游的采集质量与路由：微动模糊与曝光漂移仍会削弱 SOTA 分类器输入。全量 6,719 张评估将 Edge-IQA 标定与社区资源对接，而非仅合成占位。

定位小结。 相对通用边侧卸载，本文面向机器人采集闭环；相对 NR-IQA 文献，优先可阈值化 Q_{img} 与 JSONL 审计；相对 TCM 诊断论文，解决分类前的帧可用性。

3 方法

4 系统架构

面向中医远程舌诊的机器人舌象采集，本文采用云-边-端分层设计。实时采集与质控在边缘完成，高时延分析在云端或离线进行；算法模块与 ROS 运行时解耦，便于独立测试。

4.1 设备层

设备层包括 Franka Research 3 (FR3) 机械臂、RGB 相机与基于 ROS 2 的运动执行。MoveIt 提供关节空间点到点 (PTP) 运动。Paper I 通过边缘网关调用两个具名 *skills*: `go_to_tongue_pose` 与 `go_to_face_pose`, 关节角存于 `poses.yaml`。实验设置 `PAPER1_MODE=1` 以禁用阻抗/刚度类接口。MoveIt 假硬件与可选 Gazebo 相机支持无真机辅轨复现。

4.2 边缘层

边缘层是闭环采集的主要贡献面。FastAPI 服务 `franka_api_server` (端口 8000) 作为网关，将 HTTP 桥接至 ROS 2 运动与错误恢复动作。**Edge-IQA** 以轻量指标 Q_{img} (清晰度与曝光融合) 为

Table 1: Paper I 分层与代码仓映射。

层级	组件	位置
设备	MoveIt、skills	<code>franka_ros2</code>
边缘	FastAPI 网关	<code>franka_api_server</code>
边缘	Edge-IQA、LangGraph	<code>doctor/paper1</code>
云端	视觉桩	<code>doctor/paper1 (桩)</code>

每帧打分，代码位于 `doctor/paper1`，阶段 2 起经子进程挂载至网关。**LangGraph** 实现置信度感知路由：`capture` $\rightarrow$ `edge_iqa` $\rightarrow$ `route`，分支为 `upload_cloud`、`resample_edge`、`fail_safe`。HTTP 客户端 `sim/franka_bridge` 连接 LangGraph 与网关 (`/vision/evaluate`、`/motion/skills/...`)。

4.3 云端层

云端托管高层视觉模型与 EMR 对接 (Paper I 为桩实现)。仅当边缘质量与路由策略接受该帧时才触发上云；否则在重试预算 K 内请求边缘重采。由此保持 1 kHz ROS 控制回路不含学习型感知。

4.4 数据与时序产物

每次闭环 `trial` 将 ISO 8601 时间戳 (`t_capture`、`t_iqa`、`t_route`) 与决策写入 JSONL。主定量结果由离线 `run_matrix_tcm.py` 在 ShezhenV3-COCO 测试图像上生成 (B0-B3)；Franka 辅轨 (M6) 仅报告趋势一致的 RTT，不进入主表。

4.5 效度威胁

离线 RTT 采用文档化延迟模型；ShezhenV3 模糊标签为合成注入；真实队列上 Edge-IQA 存在组间重叠 (M5 $\rho=0.47$)，后续可探索 ROI 裁剪。

4.6 实现映射

表 1 给出架构层与代码仓映射。

图 1 为端到端信息流；设备运动仅经边缘网关下发，IQA 不嵌入 ROS 硬件插件。

4.7 边缘图像质量评估

上云前，边缘节点以轻量 *Edge-IQA* 为每帧打分；固定 512×512 缩放后复杂度 $O(HW)$ ，适合纯 CPU 网关。

质量指标。 设灰度图为 I ，Laplacian 清晰度 $S = \text{Var}(\nabla^2 I)$ 归一化至 $[0, 1]$ ，曝光项 E 在中灰处取峰值：

$$Q_{\text{img}} = 0.65 S + 0.35 E. \quad (1)$$




Figure 1: 机器人中医舌象采集的云-边-端架构 (Paper I)。

Table 2: 边侧采集门控的 IQA 路线对比 (定性)。

方法	延迟	GPU	标志	直接	τ
Edge-IQA (本文)	~ 10 ms	否	是	是	是
仅 Laplacian	~ 5 ms	否	部分	是	是
NIQE / BRISQUE	50–200 ms	否	有限	需映射	是
深度 NR-IQA	10–100+ ms	常需	否	需映射	是
B3 加成 (仿真)	同 B2	—	否	是	是

Algorithm 1 Edge-IQA 打分

将 I 缩放至 512×512 并转灰度 $S \leftarrow \text{normalize}(\text{Var}(\nabla^2 I))$
 $E \leftarrow 1 - |\text{mean}(I) - 0.5|$
 $Q_{\text{img}} \leftarrow 0.65S + 0.35E$ 由 (S, E) 导出
 $Q_{\text{img}}, \text{flags}$
 模型服务
 不适用

当 $S < \tau_s$ 或曝光偏离时, 置 `blur`、`underexposed`、`overexposed` 等标志。

设计动机。 机器人舌象采集的主要失效模式是微动模糊与曝光漂移, 而非通用压缩伪影。Edge-IQA 将清晰度与曝光融合为 $[0, 1]$ 分数, 便于用单一阈值 τ 驱动 LangGraph 路由; ShenzhenV3 验证集清晰/模糊中位数分别为 0.564 与 0.431 ($\tau^*=0.498$)。本文优先可部署性——纯 CPU、可解释标志、离线标定与在线网关共用 `scorer.py`——而非 MOS 排行榜精度。§5.1 中基线 B3 对 Q_{img} 施加仿真 +0.08 学习加成, M2 略升但属可选; 主结论仍基于可解释的 B2。

阈值 τ 。 在验证集上, 取清晰/模糊子集中位数 Q_{img} 的中点作为路由阈值 τ (限制在 $[0.45, 0.65]$), 写入 `recommended_tau.json`。

实现。 `edge_iqa/scorer.py` 运行于 `doctor/paper1`; 网关以子进程调用 `python -m edge_iqa.cli`, 避免与 `rclpy` 争用 GIL。100 帧、512px 离线测得 CPU p95 低于 30 ms (见 `latency_benchmark.json`)。

Table 3: 闭环采集 LangGraph 节点 (Paper I)。

节点	输入	输出/边
<code>capture</code>	skill 触发	RGB 帧路径
<code>edge_iqa</code>	帧	$Q_{\text{img}}, \text{flags}$
<code>route</code>	Q_{img}, r	决策
<code>resample_edge</code>	决策	重新 <code>capture</code>
<code>upload_cloud</code>	决策	云端占位
<code>fail_safe</code>	$r > K$	中止 + 日志

4.8 置信度感知路由

给定边侧质量分数 Q_{img} 与重试计数 r , 路由器在阈值 τ 与预算 K 下实现可测试三分支策略:

$$\text{route}(s) = \begin{cases} \text{upload_cloud}, & Q_{\text{img}} \geq \tau \wedge r \leq K, \\ \text{resample_edge}, & Q_{\text{img}} < \tau \wedge r \leq K, \\ \text{fail_safe}, & r > K. \end{cases} \quad (2)$$

状态与节点。 LangGraph 兼容 `TrialState` 含 `image_path`、`q_img`、`flags`、`retry_count`、`route_decision`、时间戳与 `latency_ms`。节点与边见表 3; `tests/test_routing.py` 覆盖三分支与 $r > K$ 守卫。

Algorithm 2 置信度感知路由循环 (B2)

```

 $r \leftarrow 0$ , 采集帧  $I$  ( $Q, \text{flags}$ )  $\leftarrow$ 
EDGEIQA( $I$ )  $d \leftarrow \text{ROUTE}(Q, r, \tau, K)$   $d =$ 
upload_cloud break  $d = \text{resample\_edge}$   $r \leftarrow$ 
 $r + 1$ ; 重采  $I$  fail_safe; break  $r > K$ 

```

Table 4: Paper I 闭环 JSONL 字段。

字段	说明
t_capture、t_iqa、t_route	ISO 8601 UTC 段时间
route_decision	upload_cloud resample_edge fail_safe
latency_ms	单次 trial 端到端时延

执行映射。逻辑在 langgraph_router/routing.py, 于 edge_iqa 之后调用。resample_edge 经 HTTP 网关触发 go_to_tongue_pose; upload_cloud 交云端占位模块。ShezhenV3 重放中, 重采使 r 增加并随机抬高 Q ($\Delta Q \sim \mathcal{U}(0.15, 0.35)$), 模拟重新对准后的对焦改善。

与 B1 对比。 B1 仅评估一次 Edge-IQA 并始终上云; B2 对低 Q 帧闭环重采直至 $Q_{\text{img}} \geq \tau$ 或 $r > K$, 故 M3 更高而 M2 近 1 (表 9)。

状态机见 graph.py, 支持 JSONL 导出以供补充材料审计。

4.9 闭环协议与日志

每次 trial 执行 capture $\rightarrow$ edge_iqa $\rightarrow$ route $\rightarrow$ 动作。各段时间戳与决策以 JSONL (每行一个 JSON) 追加, 用于补充材料复现及辅轨 (M6) 趋势分析。

JSONL 模式。 必填字段: trial_id、image_path (相对路径)、q_img、flags、retry_count、route_decision、t_capture、t_iqa、t_route、latency_ms。由 scripts/validate_jsonl.py 自动校验。

执行。 驱动 python -m langgraph_router.run 在无 TCM 验证集时交替使用合成清晰/模糊帧; scripts/paper1_closed_loop.sh 封装 10 次 trial 至 experiments/logs/run_001.jsonl。主定量 RTT (M1) 仍由离线 run_matrix.py 给出; JSONL 用于协议演示。

Table 5: ShezhenV3-COCO 各舌象类别标注数 (全划分合计)。

代号	含义	标注数
baitaishe	White-coating tongue	5040
hongdianshe	Red-spot tongue	3653
liewenshe	Fissured tongue	1886
chihenshe	Tooth-marked tongue	1482
hongshe	Red tongue	1466
huangtaishe	huangtaishe	1119
pangdashe	Chubby tongue	689
botaish	Peeling tongue	581
shenquao	shenquao	495
xinfeiao	xinfeiao	372
gandanao	gandanao	292
shoushe	Thin tongue	285
huataishe	huataishe	283
zish	Purple tongue	231
piweiao	piweiao	186
heitaish	heitaish	122
jiankangshe	Healthy tongue	21
gandantu	gandantu	9
shenqutu	shenqutu	2
xinfeitu	xinfeitu	2

5 实验

5.1 实验设置

在 **ShezhenV3-COCO** 测试集上评估四条基线, Edge-IQA 阈值 $\tau=0.498$ (验证集标定, 见 §5.2), 重试预算 $K=2$ 。

数据集。 ShezhenV3-COCO 含 6,719 张 RGB 舌象及 COCO 框标注、十种舌象类别。表 5 汇总标注数; 类别描述诊断形态而非采集质量, 故需独立的 Edge-IQA blur/曝光维度。官方测试集 ($n=553$) 用于主矩阵; 验证集 ($n=572$) 仅用于 τ 标定。训练集 ($n=5,594$) 预留于未来学习 IQA 扩展 (当前 B3 为 Q_{img} 仿真 +0.08 加成)。

基线。

- **B0:** 仅上云, 无边侧质量门控与智能路由。
- **B1:** 每次上云前 Edge-IQA; 无 LangGraph 路由 (不重采)。
- **B2:** Edge-IQA + LangGraph 路由器 (本文方法)。
- **B3:** B2 + 可选学习质量加成 (Q_{img} 加 0.08)。

Table 6: 关键超参数 (Paper I, ShezhenV3 验证)。

符号	取值	作用
τ	0.498	路由阈值 (验证集中位数)
K	2	最大边缘重采次数
w_s, w_e	0.65, 0.35	清晰度/曝光权重
缩放	512 ²	Edge-IQA 输入
模糊 r	2.5–5.0 px	val/test 合成失焦
B3 加成	+0.08	学习 IQA 占位

Table 7: Paper I 使用的 ShezhenV3-COCO 舌象数据集划分。

划分	图像数	用途
训练集	5594	预留 (未来微调)
验证集	572	Edge-IQA τ 标定
测试集	553	主实验矩阵 B0–B3
合计	6719	COCO 格式框标注

质量注入。 每帧随机抽取测试图像；以 0.5 概率使用原图 (清晰组)，否则施加高斯模糊 ($r \in [2.5, 5.0]$ px) 后打分——与验证集标定协议一致。每帧 Q_{img} 由 `edge_iqa/scorer.py` 计算；RTT 分量见下列延迟模型。

延迟模型。 端到端 RTT 含采集 (5 ms)、边侧 IQA ($\mathcal{N}(9, 2^2)$ ms)、路由 (1.5 ms)、可选边缘重采 (对数正态, $p50 \approx 50$ ms) 与上云 (均匀 50–550 ms)。完整机械臂运动延迟仅在 Franka 辅轨 M6 评估。见 `sim/NETEM.md`。

协议。 每基线每随机种子模拟 500 帧 ($\{0, 1, 2\}$)，得到表 9 指标 M1–M3。主表数字由 `experiments/run_matrix_tcm.py` 生成；Franka 辅轨 (M6) 单独报告于 Fig. S1，不与主表合并。

指标。 **M1** 端到端 RTT；**M2** 路由后 $Q_{\text{img}} \geq \tau$ 比例；**M3** 至少一次重采比例；**M4** τ 扫描；**M5** 验证集 Spearman ρ 。

超参数。 表 6 为 ShezhenV3 实验常量，与 `scorer.py` 默认一致。

5.2 ShezhenV3-COCO 上的 Edge-IQA 验证

本文以公开 **ShezhenV3-COCO** 舌象数据集 (6,719 张, COCO 框标注, 十种舌象类别) 替代阶段 2 合成队列。验证集 ($n=572$) 作为清晰组；对每张图施加高斯模糊 (半径 2.5–5.0 px) 模拟机器人微动失焦，构成成对模糊标签，用于阈值标定而无需人工质量标注。

Table 8: ShezhenV3 验证集 Edge-IQA 标定结果 (清晰 $n = 572$ + 合成模糊 $n = 572$)。

指标	清晰组	模糊组
Q_{img} 中位数	0.564	0.431
Q_{img} 均值	0.561	0.425
标准差	0.127	0.105
路由阈值 τ	0.498	
Spearman ρ (M5)	0.465 ($n = 1144$)	

图 2 为全验证集 Q_{img} 直方图。相对合成数据，真实舌象纹理使绝对分数降低 (清晰中位 0.564、模糊 0.431)，组间重叠增大；故除 τ 标定外报告 Spearman 相关 (M5, $\rho=0.47$)，而不声称完全可分。标定 $\tau=0.498$ 仍落在两组中位数之间，并统一用于测试集矩阵实验。

协议一致性。 测试集每帧由同一 `edge_iqa/scorer.py` 离线打分；延迟分量 (采集、IQA、路由、重采、上云) 遵循 §5.1。表 9 因此反映真实质量分数，同时保留可复现闭环仿真器用于 RTT 聚合。

分数重叠与标定策略。 真实 ShezhenV3 验证对存在分数重叠 (清晰组最小 Q_{img} 低于模糊组最大 Q_{img})，因舌象纹理与苔质在轻度失焦下仍贡献 Laplacian 能量。故同时报告组中位数与 Spearman ρ ，不假设完全可分簇。 τ 取中位数中点并限制在 $[0.45, 0.65]$ ，协议与阶段 2 一致，但以 572 张真实清晰图及成对模糊替代合成直方图。

部署含义。 尽管存在重叠，B2 在测试矩阵上 $M2=1.00$ ，因闭环重采后的 Q_{uplift} 模型与真实分数结合，仍可在 $K=2$ 内越过 τ 。运维人员可查阅 JSONL 中 `flags` 诊断失败原因，无需检查原始云上传。

与合成阶段 2 对比。 合成标定 $\tau=0.505$ ，中位数 0.819/0.191；ShezhenV3 为 $\tau=0.498$ ，中位数 0.564/0.431，M5 $\rho=0.47$ (合成约 0.75)。真实纹理使 Q_{img} 整体下移，但 B2 相对 B0/B1 的路由收益在测试集上保持，支持架构在玩具图之外的外部有效性。

5.3 主实验结果

表 9 汇总 ShezhenV3-COCO 测试集上使用真实 Edge-IQA 分数的主矩阵 (3 seeds, 每基线每 seed 500 帧)。相对朴素上云 B0, B2 将 M1 p50 从 383.6 ms 降至 341.2 ms (约 11%)，M2 从 0.52 提升至 1.00。B1 与 B0 M2 相近 (0.52)，因其仅过滤不重采；B2




Figure 2: ShezhenV3 验证集 Edge-IQA: 清晰 vs. 合成模糊成对样本 ($n=1,144$)。

Table 9: 主实验结果 (ShezhenV3-COCO 测试集, 真实 Edge-IQA 分数, 3 个种子, 553 张图像)。

基线	M1 p50 (ms)	M1 p95 (ms)	M2 有效帧率
B0	383.6	668.8	0.521
B1	314.9	540.0	0.521
B2	341.2	574.9	1.000
B3	303.7	550.5	1.000

以更高 M3 重拍率 (0.48) 换取闭环策略下接近满分的有效帧率。

图 3 为 RTT 累积分布: B2 相对 B0 整体左移。图 4 为多种子 M2; 因每 seed 共享帧计划, 方差较小。

讨论。 绝对 RTT 取决于 §5.1 延迟模型; p50 上 $B1 < B2 < B0$ 的相对顺序反映边侧重采在 upload 前恢复有效帧、减少无效云往返。B3 固定抬高 Q_{img} , 降低 M3 重拍且保持 M2; 视为可选学习 IQA 占位而非主部署方案。

结论句。 在完整公开 TCM 测试队列上, B2 相对 B0/B1 同时改善时延与有效帧率, 并保持可解释 Edge-IQA 与可审计 LangGraph 日志。

5.4 消融与跨队列分析

阈值 τ (M4)。 对 B2 在 ShezhenV3 测试帧计划上扫描并 τ (500 帧, seed 0)。图 5 显示有效帧率在 $\tau=0.498$ (验证集中位分割) 附近达峰, 更严格阈值带来适度 RTT 代价。

跨队列相关 (M5)。 全 ShezhenV3 验证集 ($n=1,144$ 清晰/模糊对) 上, Q_{img} 与二值标签 Spearman 相关 $\rho=0.47$ (cross_tcm_fd.csv)。低于合成阶段 2 ($\rho \approx 0.75$), 但平均意义下仍单调可分; τ 标定采用组中位数而非假设分数区间不交。

Franka 辅轨 (M6)。 执行栈 50 次闭环 trial 见 Fig. S1; 本地回路延迟不含云上上传仿真, 不得与表 9 数值直接对比。

可复现性。 数据集导入、 τ 标定、矩阵重放与出图由 scripts/paper1_run_tcm_full.sh 编排, 路径见 experiments/configs/tcm_paths.yaml。




Figure 3: 端到端 RTT CDF (ShezhenV3 测试集, 真实 Edge-IQA, 3 seeds)。

5.5 讨论

主矩阵解读。 表 9 宜作为固定延迟模型下相对基线比较：绝对 RTT 来自 §5.1 文档化分量，非现场 WAN 实测。核心发现：B2 相对 B0 同时降低 RTT 中位数，并在 ShezhenV3 测试帧（可部署 Edge-IQA 打分）上使 M2 达 1。B1 表明仅边侧打分而无闭环重采不够——M2 仍为 0.52，因低于阈值的帧仍上云。

质量注入真实性。 ShezhenV3 无人工模糊标签，故对半数测试帧注入高斯失焦，与验证标定一致。该设计与机器人微动失效模式一致，但可能欠建模自动增益导致的曝光闪烁；Edge-IQA 的 E 项部分补偿。未来若有专家质量评级，可采用 ROC 选 τ 替代中位数分割。

Edge-IQA 重叠。 验证对存在分数重叠 (M5 $\rho=0.47$)，说明 Laplacian-曝光融合 alone 难以完美区分真实舌象清晰/合成模糊。利用 ShezhenV3 COCO 舌框 ROI 裁剪与会话级曝光归一化是可行扩展。重叠并不否定门控价值：路由策略含时序重试，JSONL flags 支持事后解释。

学习 IQA 占位 (B3)。 B3 对 Q_{img} 统一加 0.08，降低 M3 (0.48→0.18) 且保持 M2。视为训练集微调提示而非可部署模型；Paper I 主 claim 仍为可审计 B2。

FR3 之外泛化。 辅轨使用 Franka 假硬件，但 Edge-IQA 与 LangGraph 与硬件无关：任何暴露 /vision/evaluate 与 skill 端点的边侧网关均可复现 JSONL 协议。ShezhenV3 全量验证因此将算法贡献与机器人平台解耦。

伦理与数据处理。 打分均在公开研究语料上离线进行；JSONL 不含患者标识。图像存于本地 (tcm_paths.yaml)；文稿仅含聚合统计。

迁移解读。 真实纹理使 Q_{img} 绝对值下降，Spearman 降低因清晰/模糊组重叠增大 (见 §5.2)。B2 仍保持并略强化有效帧优势，且相对 B0 改善 RTT 中位数，说明路由架构可超出合成直方图泛化。后续将在 ShezhenV3 框内 ROI 打分以收紧分离度，同时保持可解释特征。




Figure 4: 有效帧率 M2; 误差棒为 seeds 间标准差。




Figure 5: τ 消融 (M4): TCM 测试帧上 B2 的有效帧率与 RTT p50。

JSONL 审计样例。 补充材料 Listing 1 为 Franka 辅轨脱敏 JSONL 行, 字段与 §4.9 一致:

```
{"trial_id":1,"q_img":0.8075,"flags":[],
  "route_decision":"upload_cloud","latency_ms":15.89}
```

完整日志另含 ISO8601 时间戳, 由 validate_jsonl.py 校验。

算力预算。 全验证打分 (1,144 对) 加三 seed 主矩阵在笔记本 CPU 上十分钟内完成, 便于新 TCM 批次到达后频繁重标定。

Table 10: 从合成阶段 2 到 ShezhenV3 全量验证的演进。

量	合成 (阶段 2)	ShezhenV3 (全量)
标定 n	240	1,144
清晰/模糊中位数	0.819 / 0.191	0.564 / 0.431
τ	0.505	0.498
M5 Spearman ρ	≈ 0.75	0.47
每 seed 测试帧	500 (仿真 Q)	500 (真实分数)
B2 M1 p50 (ms)	364.7	341.2
B2 M2 有效帧率	0.988	1.000

Table 11: 边侧网关端点 (Paper I)。

方法	路径	用途
POST	/api/v1/vision/evaluate	上传图 E
POST	/api/v1/motion/skills/go_to_tongue_pose	舌位 skill
POST	/api/v1/motion/skills/go_to_face_pose	面位 skill
POST	/api/v1/motion/move_joints	关节 PTI
GET	/api/v1/status/joints	关节快照

6 实现细节

本节记录边侧网关接口与 ShezhenV3 全量验证的离线实验驱动, 便于第三方在不通读整个 monorepo 的情况下复现。

6.1 边侧网关 API

表 11 列出 franka_api_server 的 Paper I HTTP 端点; 启用认证时需 X-API-Key 头。

Table 12: 环境变量 (franka_api_server)。

变量	默认	作用
PAPER1_ROOT	doctor/paper1	IQA+LangGraph
PAPER1_MODE	false	禁用_controller
PAPER1_IQA_SUBPROCESS	true	子进程 scorer
PAPER1_VISION_THRESHOLD_TAU	0.55	JSON 缺失回退
FRANKA_API_PORT	8000	监听端口

Table 13: 开放科学工件索引 (Paper I, TCM 全量运行)。

工件	路径
数据集划分	doctor/paper1/experiments/splits/tcm*.json
τ 标定	recommended_tau.json
验证集分数	calibration_val.csv
主矩阵明细	main_seed*_detail.csv
Table II	table_ii.json
M5 相关	cross_tcm_fd.csv
图表	figures/fig_iqa_hist.pdf 等
一键脚本	scripts/paper1_run_tcm_full.sh
英文 PDF	latex/main.pdf
中文 PDF	latex/main-zh.pdf

Vision 契约。 网关以子进程调用 `edge_iqa.cli`, PYTHONPATH 指向 `doctor/paper1`。响应含 `q_img`、`flags`、`t_iqa_ms` 及 `recommended_tau.json` 中的 `threshold_tau`。子进程隔离避免 NumPy/PIL 阻塞 `rclpy` 执行器。

6.2 环境与配置

表 12 为常用环境变量; Paper I 实验设 `PAPER1_MODE=1` 禁用与采集无关的阻抗/碰撞路由。

6.3 离线实验驱动

ShezhenV3 验证顺序: (1) `import_shezhenv3.py`; (2) `calibrate_tau_tcm.py`; (3) `run_matrix_tcm.py`; (4) 图表/LaTeX 生成。一键脚本 `paper1_run_tcm_full.sh` 链式调用并编译 `main.pdf` / `main-zh.pdf`。

数据集路径。 Windows D:\...\shezhenv3-coco 在 WSL 映射为 `/mnt/d/...`, 仅需修改 `tcm_paths.yaml` 中 `dataset_root`。

单元测试。 `test_scorer.py`、`test_routing.py` 可在无 TCM 挂载的 CI 环境运行; 全量验证为本地可选步骤。

6.4 开放科学工件索引

表 13 索引 ShezhenV3 全量验证主要产出文件 (路径相对 `franka_ros2` 根目录)。

无 FR3 硬件亦可仅依赖 TCM 挂载与 Python 环境复现表 9; Franka 辅轨为可选。

7 结论

本文在 Franka ROS 2 栈上提出 Edge-IQA 与 Lang-Graph 置信度感知路由, 并在公开 ShezhenV3-COCO 语料 (6,719 张) 上完成端到端验证。IQA 与路由置于 1 kHz 控制回路之外, 兼顾实时安全与 JSONL 可审计闭环。在测试集真实 Edge-IQA 分数上, B2 相对朴素上云改善中位 RTT 与有效帧率; τ 消融与验证集标定 ($\tau=0.498$, M5 $\rho=0.47$) 刻画真实舌象纹理下的工作点。

局限。 验证集模糊为合成注入; 真实机器人运动剖面可能不同。真实图像上清晰/模糊组重叠表明 ROI 裁剪或学习 refinement 仍有空间 (B3 仅以仿真加成探索)。云端视觉与 EMR 仍为占位; M6 验证执行栈可行性, 不替代离线 RTT 统计。

未来工作。 舌体框条件化打分、Gazebo 相机注入、训练集微调 B3 (冻结主表协议) 及多中心临床采集研究。

References

- [1] S. Chitta, I. Sucan, and S. Cousins. Moveit! In *IEEE Robotics Automation Magazine*, volume 19, pages 18–19, 2012.
- [2] Y. Kang, J. Hu, S. Gummadi, et al. Neurosurgeon: collaborative intelligence between the cloud and mobile edge. In *ACM SIGARCH Computer Architecture News*, volume 45, pages 615–629, 2017.
- [3] E. Li, Z. Zhou, and X. Chen. Edge intelligence: on-demand deep learning model co-inference with device-edge synergy. *ACM Workshop on Mobile Computing Systems and Applications*, 2018.
- [4] S. Macenski, T. Foote, B. Gerkey, et al. Robot operating system 2: design, architecture, and uses in the wild. *Science Robotics*, 7(66):eabm6074, 2022.

- [5] A. Mittal, R. Soundararajan, and A. C. Bovik. Making a completely blind image quality analyzer. In *IEEE Signal Processing Letters*, volume 20, pages 209–212, 2013.
- [6] D. Qi, D. Zhang, and Y. Liu. Tongue image analysis for disease diagnosis. *Pattern Recognition*, 55:1–12, 2016.
- [7] W. Zhang, K. Ma, J. Yan, Z. Deng, and Z. Wang. Blind image quality assessment using a deep bilinear convolutional neural network. *IEEE Transactions on Circuits and Systems for Video Technology*, 30(1):36–47, 2020.
- [8] X. Zhang, Y. Wang, and H. Liu. Automatic tongue diagnosis: a survey. *Artificial Intelligence Review*, 53(5):3145–3187, 2020.

A 补充材料

补充材料随仓库提供：`run_001.sample.jsonl`（脱敏 trial 日志）、`REPRODUCE.md`（离线矩阵）及 `REPRODUCE_franka.md`（ ≥ 10 次网关闭环）。图 S1 汇总辅轨 M6 RTT 直方图（`fig_s1_franka_rtt.pdf`）。不含可识别患者的原始图像。




Figure 6: 辅轨闭环时延（M6， $n=50$ ）。