

面向机器人中医舌诊采集的置信度感知边缘路由： Edge-IQA 与 LangGraph 闭环采集

石洪雷* 赵涓涓
太原理工大学

Abstract

中医远程舌诊中的机器人舌象采集，需要在运动控制、端侧质量评估与上云策略之间协同配合，并适应变化的网络时延。本文提出云-边-端架构，将学习型感知移出 1 kHz 的 ROS 控制回路：轻量级 *Edge-IQA* 在网关上为每帧打分，*LangGraph* 路由器在有限重试预算 K 内决策上云、边缘重采或 fail-safe 中止。在 ShezhenV3-COCO 测试集（553 张，真实 *Edge-IQA* 与物理 Skill 重采，每 seed 500 帧、共 3 个随机种子，基线 B0-B4）上，在文档化延迟模型下，B2 相对 B0 将端到端往返时延（RTT，M1 p50）从 374.0 ms 降至 208.3 ms，有效帧率（M2）从 0.560 提升至 0.604；学习型 B3/B4 在 τ_{B2}/τ_{B3} 下 M2 可达 0.93 量级，但 M1 含 MobileNet 的 CPU 推理开销。在舌区 ROI 上标定 *Edge-IQA* 阈值 $\tau_{B2}=0.465$ （572 对验证样本），CPU p95 约 9.6 ms。Franka 辅轨闭环（50 次 trial）表明，路由决策可在真实执行栈上复现。

1 引言

中医远程舌诊要求机械臂搭载相机可重复地采集高质量舌象，以支撑云端分析与电子病历（EMR）集成 [6, 8]。临床舌诊依赖颜色、纹理、苔质与形态等特征；在微动模糊、光照不均或拍摄距离失当时，这些特征会显著退化 [8]。若采用「每帧一律上云」的朴素流水线，既浪费带宽，也会在链路较慢时放大端到端时延。

研究动机。 云边协同机器人可将重型视觉模型卸载至云端，同时保持采集闭环的响应性。但在中医成像场景中，垃圾进、垃圾出（GIGO）效应尤为突出：一次模糊上传不仅浪费一次 RTT，还可能将低置信特征传入下游分类器。因此，边侧质量门控须同时满足：(i) 足够快，可嵌入闭环；(ii) 可解释、可审计；(iii) 能在真实舌象语料上标定。ShezhenV3-COCO 提供舌体边界框，使 ROI 裁剪与下游解剖关注区对齐。

方法概述。 本文在 FR3 平台上研究云-边-端架构，采用 ROS 2 与 MoveIt。轻量 *Edge-IQA* 在 COCO 舌区 ROI 上融合 Laplacian 清晰度与曝光指标；*LangGraph* 在预算 K 内完成三分支路由决策。可选基线 B3 在训练集上微调 MobileNetV3-Small，用于与可解释路由对比。

数据集与评估规模。 在 ShezhenV3-COCO（6,719 张）上：572 对验证样本（ROI + 合成模糊）用于标定 τ ；553 张测试图、每 seed 500 帧，采用真实 *Edge-IQA* 与 B3 分数进行主矩阵评估。

主要贡献。

1. **Edge-IQA + ROI:** 在舌区裁剪上标定 $\tau^*=0.465$ ，CPU p95 低于 10 ms。
2. **LangGraph 路由:** 物理重采下 B2 将 M2 提升至 0.604（相对 B0 的 0.560），M1 p50 由 374 ms 降至 208 ms。
3. **学习型 B3 对比:** MobileNet 验证准确率 98.3%；在 τ_{B2} 下 B3 M2 为 0.934，在 $\tau_{B3}=0.5$ 下 B3t M2 为 0.929，混合 B4 M2 为 0.936，体现学习型排序与可解释路由之间的延迟-有效帧权衡。
4. **双轨评估:** ShezhenV3 主矩阵与 Franka M6 辅轨分离报告，CSV 结果不混用。

章节安排。 第 2-7 节依次介绍相关工作、方法（含 ROI 与 B3）、实验与结论。

范围说明。 本文不提出新的舌病分类器，不宣称通用 IQA 排行榜 SOTA，也不替代临床判断；研究焦点是采集时刻的质量门控与路由。

可复现性与临床转化。 一键脚本 `paper1_run_tcm_full.sh` 可重建图表与 PDF，工件存放于 `experiments/results/`。临床试点宜记录 50 次以上会话的 JSONL、在本地重标定 τ ，并对比路由前后云端分类置信度。人工重拍在流程

*通讯作者。E-mail: shihonglei0042@link.tyut.edu.cn。

上类似 `resample_edge`，但缺乏统一的 Q_{img} 阈值；Edge-IQA 将决策标准化，并导出可读的 `flags`。发布版本应固定 `scorer.py` 与 checkpoint 的 SHA256；修改 ROI padding 后须重新标定。双轨设计将算法证据（ShezhenV3）与集成证据（Franka M6）分离，便于在其他机器人传感论文中复用；ShezhenV3 图像路由 `tcm_paths.yaml` 配置。

全文定位。 Paper I 的核心主张，是在真实中医舌象数据上得到验证的置信度感知路由架构，而非新的 IQA 回归 SOTA。

2 相关工作

机器人医学成像。 手术与诊断机器人广泛采用 ROS 2 与 MoveIt [1, 4]。遥操作与自主相机须满足关节限位、避障与可重复视点，因此多采用 *skills*（标定位姿），而非临时关节遥操作。本文以 `go_to_tongue_pose`、`go_to_face_pose` 等具名 skill 替代在线阻抗调参，既满足临床可重复性，又与力控研究线程解耦。

图像质量评估。 全参考指标（PSNR、SSIM）需要 pristine 参考图，不适用于逐患者在线采集。手工 NR-IQA（Laplacian、BRISQUE、NIQE 等）无需参考图 [5]，但在路由前常需额外分数映射，且难以提供可供临床审计的 blur/曝光语义。深度 NR-IQA（DB-CNN [7]、NIMA、HyperIQA 等）在 benchmark 上感知相关性强，但依赖 GPU、模型版本管理与黑盒解释。

边侧闭环机器人更偏好线性复杂度与可审计的失效模式；本文 Edge-IQA 显式输出 blur/曝光标志，并以 τ 驱动 LangGraph（见表 2）。本文不追求通用 MOS 排行榜冠军，而关注 TCM 舌象场景下、在 CPU 延迟与可复现约束下的**边侧采集门控**。

边云协同。 分流推理与早退策略可降低移动视觉带宽 [2,3]。Neurosurgeon 类框架按层切分 DNN；本文则在重型云模型运行之前，以轻量打分器门控上传决策。相较嵌入 if-else 且无结构化轨迹导出的单体 ROS 节点，LangGraph 式状态机更易表达可审计的分支逻辑。

中医舌象分析。 云端舌象分类、分割与颜色分析已较为成熟 [6,8]。ShezhenV3-COCO 等公开语料提供框标注与类别标签，主要服务下游诊断模型。Paper I 聚焦这些模型上游的采集质量与路由：微动模糊与曝光漂移仍会削弱 SOTA 分类器的输入质量。在全部 6,719 张图像上的评估，将 Edge-IQA 标定与社区资源对接，而非仅依赖合成占位数据。

定位小结。 相对通用边侧卸载，本文面向机器人采集闭环；相对 NR-IQA 文献，优先可阈值化的 Q_{img} 与 JSONL 审计；相对 TCM 诊断论文，解决分类之前的帧可用性问题的。

3 方法

4 系统架构

面向中医远程舌诊的机器人舌象采集，本文采用云-边-端分层设计：实时采集与质控在边缘完成，高时延分析在云端或离线进行；算法模块与 ROS 运行时解耦，便于独立测试与回归。

4.1 设备层

设备层包括 Franka Research 3 (FR3) 机械臂、RGB 相机，以及基于 ROS 2 的运动执行栈。MoveIt 提供关节空间点到点（PTP）运动。Paper I 通过边缘网关调用两个具名 *skills*：`go_to_tongue_pose` 与 `go_to_face_pose`，关节角配置存于 `poses.yaml`。实验设置 `PAPER1_MODE=1`，以禁用阻抗/刚度类接口。MoveIt 假硬件与可选 Gazebo 相机支持无真机条件下的辅轨复现。

4.2 边缘层

边缘层是闭环采集的主要贡献所在。FastAPI 服务 `franka_api_server`（端口 8000）作为网关，将 HTTP 请求桥接至 ROS 2 运动与错误恢复动作。**Edge-IQA** 以轻量指标 Q_{img} （清晰度与曝光融合）为每帧打分，实现位于 `doctor/paper1`，自阶段 2 起经子进程挂载至网关。**LangGraph** 实现置信度感知路由：`capture` $\rightarrow$ `edge_iqa` $\rightarrow$ `route`，分支包括 `upload_cloud`、`resample_edge` 与 `fail_safe`。HTTP 客户端 `sim/franka_bridge` 连接 LangGraph 与网关（`/vision/evaluate`、`/motion/skills/...` 等）。

4.3 云端层

云端托管高层视觉模型与 EMR 对接接口（Paper I 中为桩实现）。仅当边缘质量与路由策略接受该帧时，才触发上云；否则在重试预算 K 内请求边缘重采。由此保持 1 kHz ROS 控制回路中不含学习型感知模块。

4.4 数据与时序产物

每次闭环 trial 将 ISO 8601 时间戳（`t_capture`、`t_iqa`、`t_route`）与路由决策写入 JSONL。主定量结

Table 1: Paper I 分层与代码仓映射。

层级	组件	位置
设备	MoveIt、skills	franka_ros2
边缘	FastAPI 网关	franka_api_server
边缘	Edge-IQA、LangGraph	doctor/paper1
云端	视觉桩	doctor/paper1 (桩)

果由离线脚本 `run_matrix_tcm.py` 在 ShezhenV3-COCO 测试图像上生成 (基线 B0-B3); Franka 辅轨 (M6) 仅报告趋势一致的 RTT, 不并入主表。

4.5 效度威胁

离线 RTT 采用文档化延迟模型; ShezhenV3 的模糊标签为合成注入; 在真实队列上, Edge-IQA 仍存在组间分数重叠 (M5: $\rho=0.47$), 后续可进一步结合 ROI 裁剪与学习 refinement。

4.6 实现映射

表 1 给出架构分层与代码仓的对应关系。

图 1 概括端到端信息流: 设备运动仅经边缘网关下发, IQA 不嵌入 ROS 硬件插件。

4.7 边缘图像质量评估

上云之前, 边缘节点以轻量 *Edge-IQA* 为每帧打分; 在固定 512×512 缩放后, 计算复杂度为 $O(HW)$, 适合纯 CPU 网关部署。

质量指标。 设灰度图为 I , Laplacian 清晰度 $S = \text{Var}(\nabla^2 I)$ 归一化至 $[0, 1]$, 曝光项 E 在中灰处取峰值:

$$Q_{\text{img}} = 0.65 S + 0.35 E. \quad (4.1)$$

当 $S < \tau_s$ 或曝光偏离时, 置 `blur`、`underexposed`、`overexposed` 等标志位。

设计动机。 机器人舌象采集的主要失效模式是微动模糊与曝光漂移, 而非通用压缩伪影。Edge-IQA 将清晰度与曝光融合为 $[0, 1]$ 分数, 便于用单一阈值 τ 驱动 LangGraph 路由; 启用 COCO 舌区 ROI 后, ShezhenV3 验证集上清晰/模糊子集的中位数分别为 0.516 与 0.414 ($\tau^*=0.465$)。本文优先追求可部署性——纯 CPU、可解释标志、离线标定与在线网关共用 `scorer.py`——而非 MOS 排行榜精度。基线 B3 (§D.1) 为在 ShezhenV3 训练集上微调的 MobileNetV3-Small, 仅作可选对比; 主结论仍基于可解释的 B2。

Table 2: 边侧采集门控的 IQA 路线对比 (定性)。

方法	延迟	GPU	标志	直接 τ	同一 scorer
Edge-IQA (本文)	~ 10 ms	否	是	是	是
仅 Laplacian	~ 5 ms	否	部分	是	是
NIQE / BRISQUE	50–200 ms	否	有限	需映射	需封装
深度 NR-IQA	10–100+ ms	常需	否	需映射	模型服务
B3 加成 (仿真)	同 B2	—	否	是	不适用

Algorithm 1 Edge-IQA 打分

- 1: 将 I 缩放至 512×512 并转灰度
- 2: $S \leftarrow \text{normalize}(\text{Var}(\nabla^2 I))$
- 3: $E \leftarrow 1 - |\text{mean}(I) - 0.5|/0.5$
- 4: $Q_{\text{img}} \leftarrow 0.65S + 0.35E$
- 5: 由 (S, E) 导出 flags **return** Q_{img} , flags

阈值 τ 。 在验证集上, 取清晰/模糊子集中位数 Q_{img} 的中点作为路由阈值 τ (限制在 $[0.45, 0.65]$), 并写入 `recommended_tau.json`。

实现。 `edge_iqa/scorer.py` 运行于 `doctor/paper1`; 网关以子进程调用 `python -m edge_iqa.cli`, 避免与 `rclpy` 争用 GIL。在 100 帧、512px 的离线测试中, CPU p95 低于 30 ms (见 `latency_benchmark.json`)。

4.8 COCO 舌区 ROI 裁剪

ShezhenV3-COCO 以 COCO 格式 $[x, y, w, h]$ 提供舌体边界框。存在多框时取并集, 各边外扩 8% (不超出图像边界) 后裁剪, 再送入 Edge-IQA 的 512×512 缩放流程。实现位于 `edge_iqa/coco_roi.py`; `import_shezhenv3.py` 导入数据后, 在划分 JSON 中写入 `bboxes` 字段。

动机。 全图评分会纳入脸颊、牙齿与背景纹理, 其 Laplacian 能量与舌面清晰度并不一致。ROI 裁剪使质量信号与下游 TCM 分类器的解剖关注区对齐, 并降低对视野外高对比结构 (如唇缘、牙面高光) 的敏感度。

标定影响。 在完整验证集 (572 张清晰图, 各配对一个合成高斯模糊, $r \in [2.5, 5.0]$) 上, 表 3 对比全图与 ROI 两种 Edge-IQA 设置。ROI 降低绝对中位数 (清晰 0.516 vs. 0.564; 模糊 0.414 vs. 0.431), 原因是背景高频成分被移除。「最小清晰减最大模糊」的分离度在两种设置下均为负 (ROI: -0.541 ; 全图: -0.510), 说明队列重叠仍然存在; 因此同时报告 Spearman ρ 与路由指标, 而非假设分数区间完全可分。本修订中, ShezhenV3 实验默认启用 ROI (`tcm_paths.yaml` 中 `use_roi: true`)。




Figure 1: 机器人中医舌象采集的云-边-端架构 (Paper I)。

Table 3: Edge-IQA 标定: 全图 vs. COCO 舌区 ROI (ShezhenV3 val, 每类 $n=572$)。

设置	清晰中位数	模糊中位数	τ	分离度
全图	0.564	0.431	0.498	-0.510
舌区 ROI	0.516	0.414	0.465	-0.541

部署说明。 运行时若无 COCO 框 (例如未接检测器的单相机原型), 可设 `use_roi=false` 回退至全图评分。离线标定始终使用数据集标注, 以保证可复现。

4.9 置信度感知路由

给定边侧质量分数 Q_{img} 与重试计数 r , 路由器在阈值 τ 与预算 K 下实现可测试的三分叉策略:

$$\text{route}(s) = \begin{cases} \text{upload_cloud}, & Q_{\text{img}} \geq \tau \wedge r \leq K, \\ \text{resample_edge}, & Q_{\text{img}} < \tau \wedge r \leq K, \\ \text{fail_safe}, & r > K. \end{cases} \quad (4.2)$$

实验中最大重试次数为 $K = 2$ 。

`TrialState` (LangGraph 兼容 `TypedDict`) 携带 `image_path`、`q_img`、`flags`、`retry_count`、`route_decision`、ISO-8601 时间戳及 `latency_ms`, 在 `graph.py` 中定义; `tests/test_routing.py` 覆盖全部三个分支 (4 项测试通过)。

表 4 枚举六个节点及条件边。在 ShezhenV3 重放中, 每次 `resample_edge` 对清晰参考帧施加物理 Skill 变换 (减小 blur 半径或校正曝光) 后重新打分, 不使用随机 Q 抬升。

Table 4: LangGraph 节点与条件边。

节点	输入	输出/边
<code>capture</code>	skill 触发	RGB 帧路径
<code>edge_iqa</code>	帧路径	Q_{img} , <code>flags</code>
<code>route</code>	Q_{img} , r	决策
<code>resample_edge</code>	决策	重新 <code>capture</code>
<code>upload_cloud</code>	决策	云端占位
<code>fail_safe</code>	$r > K$	中止并写 JSONL




Figure 2: LangGraph 置信度感知路由流程 (节点与条件边)。

4.9.1 为什么选择 LangGraph ?

路由决策本身足够快, 框架选择对 RTT 的影响可忽略。在 1000 次 trial (5 轮重复) 上对六种替代方案做基准测试 (表 5): 所有框架的路由开销均低于 5ms/千次 trial, 仅占 RTT 的 **0.004%**; 全链路 I/O 占比超过 99.9%, LangGraph 的额外开销约 15 μ s/次, 可忽略不计。

除吞吐量外, LangGraph 相较普通有限状态机还提供三项能力: (1) **断点持久化**——可在任意 trial 处中断后恢复; (2) **条件边可视化**——图 2 由图定义自动生成; (3) **论文 II 复用**——多 Agent 编排需要同一图抽象。

Algorithm 2 置信度感知路由循环 (B2)

```

1:  $r \leftarrow 0$ , 采集帧  $I$ 
2: repeat
3:    $(Q, \text{flags}) \leftarrow \text{EdgeIQA}(I)$ 
4:    $d \leftarrow \text{Route}(Q, r, \tau, K)$   $\triangleright$  见式 (4.2)
5:   if  $d = \text{upload\_cloud}$  then
6:     break
7:   else if  $d = \text{resample\_edge}$  then
8:      $r \leftarrow r + 1$ ; 重采  $I$   $\triangleright$  物理 Skill 变换
9:   else
10:    fail\_safe; break
11:  end if
12: until  $r > K$ 

```

Table 5: 路由框架基准测试 (1000 次 trial $\times$ 5 轮)。

框架	中位 (ms)	P95 (ms)	LOC	内存 (MB)
Plain Python	1.32	2.74	15	34.2
Vanilla FSM	1.75	3.73	15	35.5
Dataclass FSM	7.32	10.09	26	37.6
Pydantic FSM	4.38	5.60	26	37.6
Async FSM	3.02	5.36	15	37.6
LangGraph (本文)	4.95	5.15	78	46.7

场景 A (仅路由)。LangGraph 额外 3.63 ms/千次 trial (约 3.6 μ s/次), 占 360 ms RTT 的 0.004%; 全链路 I/O 超过 99.9%, 框架开销可忽略。

4.9.2 算法扩展 (B2d/B2m/B2u)。

基线 B2 使用验证集中位数作为固定 τ_{B2} 。三项扩展 (dynamic_tau.py、multi_frame_iqa.py、utility_route.py) 在不改变主部署路径的前提下, 增强算法侧的可探索性:

$$\tau_t = \tau_0 + \alpha \frac{\text{RTT}_t}{\text{RTT}_{\text{ref}}} + \beta P_{\text{loss}} \quad (4.3)$$

$$Q_t = \lambda Q_{t-1} + (1 - \lambda) Q_{\text{img}} \quad (4.4)$$

$$U = w_1 Q - w_2 \frac{\text{RTT}}{\text{RTT}_{\text{ref}}} - w_3 C \quad (4.5)$$

B2d 在网络劣化时提高上传门槛; **B2m** 对短 burst 多帧做 EMA 融合后再路由; **B2u** 以效用函数替代式 (4.2)。快速消融 (60 帧、seed 0、物理重采) 显示: B2 的 M2 为 0.60; B2m/B2u 为 0.65; B2m 因多帧 IQA 增加约 69 ms 的 p50 延迟; 全量 3 seeds 结果待 paper1_run_tcm_full.sh 产出。

JSONL 与隐私。JSONL 必填字段包括: trial_id、image_path (相对路径, 利于隐私保护)、q_img、flags、retry_count、route_decision、t_capture、t_iqa、t_route、latency_ms, 由 scripts/validate_jsonl.py 自动校验。驱动命令 `python -m langgraph_router.run --trials 10` 可生成 experiments/logs/run_001.jsonl。

Table 6: Paper I 闭环 JSONL 字段。

字段	说明
t_capture、t_iqa、t_route	ISO 8601 UTC 段时间
route_decision	upload_cloud resample_edge fail_safe
latency_ms	单次 trial 端到端时延

JSONL 仅存相对路径; 补充样例使用合成或脱敏图像, 不含原始患者数据。

4.10 闭环协议与日志

每次 trial 依次执行 capture $\rightarrow$ edge_iqa $\rightarrow$ route $\rightarrow$ 动作。各段的时间戳与决策以 JSONL 形式追加 (每行一个 JSON 对象), 用于补充材料复现及辅轨 (M6) 趋势分析。

JSONL 模式。必填字段包括: trial_id、image_path (相对路径)、q_img、flags、retry_count、route_decision、t_capture、t_iqa、t_route、latency_ms。格式由 scripts/validate_jsonl.py 自动校验。

执行方式。驱动命令 `python -m langgraph_router.run` 在无 TCM 验证集时, 交替使用合成清晰/模糊帧; scripts/paper1_closed_loop.sh 将 10 次 trial 封装输出至 experiments/logs/run_001.jsonl。主定量 RTT (M1) 仍由离线脚本 run_matrix_tcm.py 聚合; JSONL 主要用于协议演示与审计。

5 实验

5.1 实验设置

在 ShezhenV3-COCO 测试集上评估离线基线 B0-B4。主矩阵在 COCO 舌区 ROI 上打分, 路由阈值 $\tau_{B2}=0.465$ (验证集标定, §5.2, 表 10); 全图标定阈值为 $\tau_{\text{full}}=0.498$ (仅用于 ROI 消融)。重试预算 $K=2$ 。

数据集。ShezhenV3-COCO 含 6,719 张 RGB 舌象及 COCO 框标注, 覆盖十种舌象类别。表 7 汇总各类别标注数; 类别描述的是诊断形态而非采集质量, 因此需要独立的 Edge-IQA blur/曝光维度。官方测试集 ($n=553$) 用于主矩阵; 验证集 ($n=572$) 仅用于 τ 标定。训练集 ($n=5,594$) 用于可选 MobileNet B3 对照 (§D.1)。

基线。

- **B0**: 仅上云, 无边侧质量门控与智能路由。

Table 7: ShezhenV3-COCO 各舌象类别标注数（全划分合计）。

代号	含义	标注数
baitaishe	White-coating tongue	5040
hongdianshe	Red-spot tongue	3653
liewenshe	Fissured tongue	1886
chihenshe	Tooth-marked tongue	1482
hongshe	Red tongue	1466
huangtaishe	huangtaishe	1119
pangdashe	Chubby tongue	689
botaishe	Peeling tongue	581
shenquao	shenquao	495
xinfeiao	xinfeiao	372
gandanao	gandanao	292
shoushe	Thin tongue	285
huataishe	huataishe	283
zishe	Purple tongue	231
piweiao	piweiao	186
heitaishhe	heitaishhe	122
jiankangshe	Healthy tongue	21
gandantu	gandantu	9
shenqutu	shenqutu	2
xinfeitu	xinfeitu	2

- **B1**: 每次上云前执行 Edge-IQA, 但无 Lang-Graph 路由 (不重采)。
- **B2**: Edge-IQA + LangGraph 路由器 + 物理边缘重采 (本文主路径)。
- **B3/B3t/B4**: 学习型 MobileNet IQA 与混合门控 (表 12), 与主表 B0-B2 分表报告。

质量注入。 每帧随机抽取一张测试图像; 以 0.5 概率使用原图 (清晰组), 否则施加高斯模糊 ($r \in [2.5, 5.0]$ px) 后再打分——与验证集标定协议一致。每帧 Q_{img} 由 `edge_iqa/scorer.py` 计算; RTT 各分量见下文延迟模型。

延迟模型。 端到端 RTT 包括: 采集 (5 ms)、边侧 IQA ($\mathcal{N}(9, 2^2)$ ms)、路由 (1.5 ms)、可选边缘重采 (对数正态, $p_{50} \approx 50$ ms) 与上云 (均匀 50–550 ms)。完整机械臂运动延迟仅在 Franka 辅轨 M6 中评估; 详见 `sim/NETEM.md`。

实验协议。 每个基线、每个随机种子模拟 500 帧 (种子集合 $\{0, 1, 2\}$), 得到表 11 中的指标 M1–M3。主表数字由 `experiments/run_matrix_tcm.py` 读取 `recommended_tau.json` 生成; Franka 辅轨 (M6) 单独报告于图 S1, 不与主表合并。

Table 8: 关键超参数 (Paper I, ShezhenV3 主矩阵)。

符号	取值	作用
τ_{B2} (ROI)	0.465	路由阈值 (主表 II)
τ_{full}	0.498	全图标定 (仅消融)
K	2	最大边缘重采次数
w_s, w_e	0.65, 0.35	清晰度/曝光权重
缩放	512^2	Edge-IQA 输入
模糊 r	2.5–5.0 px	val/test 合成失焦
τ_{B3}	0.5	学习 IQA (表 III)

Table 9: Paper I 使用的 ShezhenV3-COCO 舌象数据集划分。

划分	图像数	用途
训练集	5594	预留 (未来微调)
验证集	572	Edge-IQA τ 标定
测试集	553	主实验矩阵 B0–B3
合计	6719	COCO 格式框标注

评价指标。 **M1**: 端到端 RTT; **M2**: 路由后 $Q_{\text{img}} \geq \tau$ 的比例 (有效帧率); **M3**: 至少发生一次重采的比例; **M4**: τ 扫描; **M5**: 验证集 Spearman ρ 。

超参数。 表 8 列出 ShezhenV3 主矩阵常量, 与 `scorer.py` 默认配置一致。

5.2 ShezhenV3-COCO 上的 Edge-IQA 验证

本文以公开 **ShezhenV3-COCO** 舌象数据集 (6,719 张, COCO 框标注, 十种舌象类别) 替代阶段 2 的合成队列。验证集 ($n=572$) 作为清晰组; 对每张图施加高斯模糊 (半径 2.5–5.0 px) 以模拟机器人微动失焦, 构成成对模糊标签, 用于阈值标定而无需人工质量标注。

图 3 为验证集 Q_{img} 的直方图。启用 COCO 舌区 ROI 时, 清晰/模糊中位数为 0.516/0.414, 部署阈值 $\tau_{B2}=0.465$ (表 10)。全图模式下中位数为 0.564/0.431, $\tau_{\text{full}}=0.498$ (表 3)。真实舌象纹理增大组间重叠, 故除 τ 标定外还报告 Spearman 相关 (**M5**: $\rho \approx 0.36$ –0.47), 而不声称完全可分。主矩阵 (`run_matrix_tcm.py`) 统一使用 ROI 分数及 `recommended_tau.json` 中的 τ_{B2} 。

协议一致性。 测试集每帧由同一 `edge_iqa/scorer.py` 离线打分; 延迟分量 (采集、IQA、路由、重采、上云) 遵循 §5.1。表 11 因此反




Figure 3: ShezhenV3 验证集 Edge-IQA：清晰 vs. 合成模糊成对样本 ($n=1,144$)。

Table 10: ShezhenV3 验证集 Edge-IQA 标定结果 (清晰 $n = 572$ + 合成模糊 $n = 572$)。

指标	清晰组	模糊组
Q_{img} 中位数	0.516	0.414
Q_{img} 均值	0.519	0.414
标准差	0.116	0.102
路由阈值 τ	0.465	
Spearman ρ (M5)	0.363 ($n = 1144$)	

映真实质量分数，同时保留可复现的闭环仿真器用于 RTT 聚合。

5.3 主实验结果

表 11 汇总主基线 B0–B2 (物理 Skill 重采, τ_{B2} , 3 个随机种子)。表 12 进一步报告 MobileNet B3 (τ_{B2} / τ_{B3}) 与混合门控 B4。

相对 B0 (M2= 0.560), B2 在物理重采下将 M2 提升至 0.604, M1 p50 降至 208.3ms (表 11 为三 seed 均值 $\pm$ 标准差)。B3 在 τ_{B2} 下 M2 达 0.934, B4 混合门控 M2 为 0.936, 但 M1 高约 135ms (见表 12)。

Table 11: 主实验结果 (ShezhenV3 测试集, 553 张; 真实 Edge-IQA, 物理重采, τ_{B2} , 3 个随机种子)。表中为各 seed 均值 $\pm$ 标准差。

基线	M1 p50 (ms)	M1 p95 (ms)	M2 有效帧率	M3 重拍率
B0	374.0 $\pm$ 7.9	656.9 $\pm$ 2.9	0.560 $\pm$ 0.007	0.000 $\pm$ 0.000
B1	322.7 $\pm$ 15.6	534.1 $\pm$ 1.2	0.560 $\pm$ 0.007	0.000 $\pm$ 0.000
B2	208.3 $\pm$ 2.8	526.9 $\pm$ 2.3	0.604 $\pm$ 0.005	0.440 $\pm$ 0.007

Table 12: 学习型 IQA 与混合门控 (ShezhenV3 测试集, 物理重采, 3 seeds)。单元格报告 seeds 上的均值 $\pm$ 标准差。

基线	M1 p50 (ms)	M1 p95 (ms)	M2 有效帧率	M3 重拍率
B3 (MobileNet, $\tau_{B2}=0.465$)	345.6 $\pm$ 8.1	606.8 $\pm$ 5.1	0.934 $\pm$ 0.012	0.481 $\pm$ 0.007
B3r (MobileNet, $\tau_{B3}=0.5$)	341.4 $\pm$ 12.5	609.6 $\pm$ 7.4	0.929 $\pm$ 0.011	0.481 $\pm$ 0.007
B4 (混合 Tier-A/B)	343.1 $\pm$ 10.0	617.7 $\pm$ 6.3	0.936 $\pm$ 0.006	0.440 $\pm$ 0.007

结果解读。 绝对 RTT 取决于所采用的延迟模型; 基线间的相对顺序反映物理重采减少了无效的云往返。
部署建议: B2 仍是首选部署路径; B4 混合 Tier-A/B 适合对有效帧率要求更高、且可接受额外边缘算力的场景。




Figure 4: 端到端 RTT 的累积分布 (ShezhenV3 测试集, 物理重采, 3 seeds)。

Table 13: 路由扩展快速消融 (seed 0, $n=60$, 物理重采)。

基线	M1 p50 (ms)	M2	M3
B2 (固定 τ)	211.3	0.600	0.417
B2d (动态 τ_t)	209.0	0.550	0.467
B2m (EMA 融合)	280.4	0.650	0.417
B2u (效用 U)	205.4	0.650	0.367

5.4 消融与跨队列分析

算法扩展 (快速消融)。 表 13 在 60 帧 ShezhenV3 测试计划 (seed 0、物理重采) 上, 对比固定 τ 的 B2 与 B2d/B2m/B2u。B2m/B2u 将 M2 从 0.60 提升至 0.65; B2m 因多帧 IQA 增加约 69ms 的 p50 延迟; B2d 在模拟丢包下略偏保守。全量 3 seeds 与网络扰动曲线见补充材料。

阈值 τ (M4)。 对 B2 在 ShezhenV3 测试帧计划上扫描五个 τ 值 (500 帧, seed 0)。图 6 给出 M4 的有效帧率-RTT 权衡; 主矩阵采用 ROI 标定的 $\tau_{B2}=0.465$ (表 10), 全图 $\tau_{full}=0.498$ 见 ROI 消融表。

5.5 讨论

主矩阵解读。 表 11 在文档化延迟模型下 (§5.1) 给出基线相对比较, 绝对 RTT 并非现场医院网络实测。在物理重采与舌区 ROI Edge-IQA ($\tau_{B2}=0.465$) 下, B2 的 M1 p50 由 374ms (B0) 降至 208ms, M2 由 0.560 升至 0.604。B1 无闭环重采时 M2 仍为 0.560, 说明重采策略是有效帧率提升的关键。学习型 B3/B4 在重标定阈值下 $M2 \approx 0.93$ (表 12), 但边侧 RTT 更高; M6 辅轨验证路由趋势, 不混入表 II。

ROI、标定与合成模糊。 COCO 舌区 ROI (8% padding) 使评分聚焦解剖区域, 但未消除 Laplacian 上的 clear/blur 重叠 (表 3)。全图标定 $\tau_{full}=0.498$; 主矩阵采用 ROI 中位数 0.516/0.414 与 $\tau_{B2}=0.465$ 。验证/测试集一半帧施加高斯模糊以模拟失焦; M5 Spearman $\rho \approx 0.36-0.47$ 反映真实纹理下的组间重叠。

可部署性: B2 与学习对照。 MobileNet (验证准确率 98.3%) 在 τ_{B2} 下 M2 为 0.934, 高于 B2 的 0.604。主路径仍为可解释、低延迟的 B2; 对有效帧率要求更高的场景可选 B3/B4, 并单独标定 τ_{B3} 。




Figure 5: 有效帧率 M2；误差棒为各 seed 间的标准差。




Figure 6: τ 消融 (M4): TCM 测试帧上 B2 的有效帧率与 RTT p50。

泛化与临床 workflow。 算法与 FR3 解耦；任意提供 /vision/evaluate 与技能端点的边侧网关均可复现 JSONL 协议。人工重拍缺乏一致的 Q_{img} 阈值，Edge-IQA 提供可审计的 flags。临床试点宜记录 JSONL、在本地重标定 τ_{B2} ，并对比路由前后云端分类置信度。

局限与可用性。 合成模糊与分数重叠限制直接临床外推；失败模式见 §E.7。实验使用离线公开语料，JSONL 不含患者标识；代码见 doctor/paper1/ 与 franka_api_server/。

全文结论。 本文贡献是在真实中医舌象数据上得到验证的路由架构证据链，而非 IQA 回归榜冠军。

6 结论

7 结论

本文在 Franka ROS 2 栈上提出 Edge-IQA 与 LangGraph 置信度感知路由，并在公开 ShezhenV3-COCO 语料 (6,719 张) 上完成端到端验证。IQA 与路由置于 1 kHz 控制回路之外，兼顾实时安全与 JSONL 可审计闭环。在测试集真实舌区 ROI Edge-IQA 分数上，B2 相对朴素上云改善 RTT 中位数与有效帧率 (M1 p50 208 ms vs. 374 ms; M2 0.604 vs. 0.560)，主矩阵阈值为 $\tau_{B2}=0.465$ ；M5 $\rho \approx 0.36-0.47$ 刻画真实纹理下的重叠。

局限。 (1) 验证/测试模糊为合成各向同性高斯失焦，可能低估机器人微振或唾液反光导致的方向性运动模糊。(2) 真实图像上清晰/模糊组分数重叠，表明可解释 B2 与学习型 B3/B4 需按场景权衡。(3) M2 (有效帧率) 是评分器内部指标；将 Edge-IQA 门控与下游分类器性能做端到端临床验证仍为后续工作。(4) 3 个随机种子提供了一致趋势，但统计检验功效有限；更多种子下的 bootstrap 置信区间将增强证据。(5) 经典无参考 IQA (NIQE/BRISQUE) 在相同 LangGraph 路由下的定量比较尚未纳入主矩阵。(6) 云端视觉与 EMR 仍为占位实现；M6 验证执行栈可行性，不替代真实临床部署数据。临床试点应在 50+ 本地会话上重标定 τ_{B2} 后再外推站点策略。

未来工作。 包括舌体框条件化打分、Gazebo 相机注入、在相同重采协议下补充 NR-IQA 基线、冻结主表脚本前提下微调 B3，以及多中心临床采集研究。

致谢与声明

作者贡献 (CRedit)。 石洪雷：概念化、方法论、软件开发、验证、数据整理、论文撰写 (初稿)、可视化。赵涓涓：项目监督、资源支持、论文修订与审阅、经费获取。

生成式 AI。 作者使用生成式 AI 辅助英文润色、 $\text{\LaTeX}$ 结构检查与仓库文档整理。所有科学结论、数值结果与代码路径均由作者对照 `experiments/results/*.json` 及复现脚本核验；未经脚本再生的指标不由 AI 直接改写。

资助与利益冲突。 本研究由太原理工大学科研项目支持。作者声明无相关财务利益冲突。

数据可用性。 ShezhenV3-COCO 为公开研究语料，可于其原始发布站点获取。所有代码、数据划分、标定制品及复现脚本均在 `doctor/paper1/experiments/` 中提供。Paper I 离线实验不招募新受试者，JSONL 日志不含患者标识。

References

- [1] S. Chitta, I. Sucan, and S. Cousins. Moveit! *IEEE Robotics & Automation Magazine*, 19(1):18–19, 2012.
- [2] Y. Kang, W. Hu, S. Gummadi, et al. Neurosurgeon: Collaborative intelligence between the cloud and mobile edge. In *Proceedings of the Twenty-Second International Conference on Architectural Support for Programming Languages and Operating Systems*, pages 615–629, 2017.
- [3] E. Li, Z. Zhou, and X. Chen. Edge intelligence: On-demand deep learning model co-inference with device-edge synergy. In *Proceedings of the ACM Workshop on Mobile Computing Systems and Applications*, 2018.
- [4] S. Macenski, T. Foote, B. Gerkey, et al. Robot operating system 2: Design, architecture, and uses in the wild. *Science Robotics*, 7(66):eabm6074, 2022.

- [5] A. Mittal, R. Soundararajan, and A. C. Bovik. Making a “completely blind” image quality analyzer. *IEEE Signal Processing Letters*, 20(3):209–212, 2013.
- [6] D. Qi, D. Zhang, and Y. Liu. Tongue image analysis for disease diagnosis. *Pattern Recognition*, 55:1–12, 2016.
- [7] W. Zhang, K. Ma, J. Yan, Z. Deng, and Z. Wang. Blind image quality assessment using a deep bilinear convolutional neural network. *IEEE Transactions on Circuits and Systems for Video Technology*, 30(1):36–47, 2020.
- [8] X. Zhang, Y. Wang, and H. Liu. Automatic tongue diagnosis: a survey. *Artificial Intelligence Review*, 53(5):3145–3187, 2020.

A 补充材料

一键复现。 在仓库根目录执行 `bash scripts/paper1_run_tcm_full.sh`，将依次完成：导入划分、训练 B3、ROI 标定 τ 、主矩阵 (3 seeds)、图表与 PDF 生成。

工件清单。

- `tcm_{train,val,test}.json`: 共 6719 张，含 COCO bboxes；
- `recommended_tau.json`: ROI 标定 ($n=1144$)；
- `roi_ablation.json`: 全图 vs. 舌区 ROI；
- `b3_mobilenet.pt`、`b3_training_meta.json`: B3 权重与验证准确率；
- `calibration_val.csv`、`main_seed*_detail.csv`: 分数与帧级日志。

环境与超参数。 Edge-IQA 仅需 NumPy/Pillow；B3 训练使用 `doctor/paper1/.venv` (PyTorch)。WSL 下数据集路径见 `tcm_paths.yaml`。Edge-IQA: 512 缩放，清晰度/曝光权重 0.65/0.35；ROI padding 8%。B3: MobileNetV3-Small, 224 输入, AdamW 10^{-3} , 5 epoch, batch 64。路由: τ 来自验证集中位数, $K=2$ 。

JSONL 字段。 `trial_id`、`image_path`、`q_img`、`flags`、`retry_count`、`route_decision`、`latency_ms`、`t_capture`、`t_iqa`、`t_route`。

局限与伦理。 合成高斯模糊；运行时需检测框或检测器；B3 与 Edge-IQA 的 τ 标度不一致；M6 不与表 II 直接对比。使用公开 ShezhenV3-COCO；JSONL 不含患者标识。

未来工作与摘要表。 端侧舌检测 ROI；混合 Edge-IQA+B3 头；基于 FR3 日志的运动模糊增广。表 S1：全图 $\tau=0.498$ ，ROI $\tau=0.465$ （详见 `roi_ablation.json`）。表 S2：5594 训练图，11188 对，验证准确率 98.3%。

计划中的 NR-IQA 基线。 NIQE/BRISQUE 在相同 LangGraph 重采协议下的定量行尚未纳入表 II；方法节表 2 为定性对比，后续将补充 CPU 可部署的无参考 IQA 行（相同 τ 标定与 3 seeds）。

命令清单。 标定：`python3 experiments/edge_iqa/calibrate_tau_tcm.py`；B3 训练：`.venv/bin/python experiments/edge_iqa/train_b3_mobilenet.py`；主矩阵：`.venv/bin/python experiments/run_matrix_tcm.py`。

版本、许可与排查。 2026-05-30：ROI + 真实 B3 + ShezhenV3 全量验证纳入正文。算法问题见 `docs-zh/paper1/study/`；代码许可 Apache-2.0，ShezhenV3 遵循其公开许可。图 S1：M6 Franka RTT 直方图见 `fig_s1_franka_rtt.pdf`。扩展阅读：V19 大纲 `docs-zh/paper1/V19/`；网关环境变量 `docs-zh/paper1/V19/ENV.md`。若 `b3_mobilenet.pt` 缺失，主矩阵 B3 回退 `b3_q_boost`（默认已关闭 `b3_use_learned`）。B3 训练在 CPU 上约 45 分钟（5594 图 $\times$ 5 epoch）；可用 `--max-train` 做 smoke test。中文稿与英文稿章节同步；表 II 由 `sync_table_ii_zh.py` 自动生成。投稿包不含原始患者图像，仅含统计与脚本；生产环境须配置 `FRANKA_API_KEY`。

补充材料定位。 本补充材料旨在使审稿人与学生可在无 FR3 硬件条件下复现表 II 与标定数字。

B 扩展算法与表格

多种子分解与数据统计。 Seed 0-2 上，B2 的 M2 为 0.60-0.61；B3 为 0.92-0.94（物理重采，见表 21）。划分规模：train 5594 / val 572 / test 553；其中 5404 张训练图含框。

Algorithm 3 COCO ROI 裁剪（并集 + padding）

- 1: **输入：** 图像 I ，框集合 $\{b_j = [x, y, w, h]\}$ ，padding p
- 2: $B \leftarrow$ 所有框的并集
- 3: 各边按 p 比例外扩并裁剪至图像边界 **return** `crop( $I, B$ )`

Table 14: B3 训练超参数（ShezhenV3 train）。

超参数	取值
结构	MobileNetV3-Small（ImageNet 初始化）
输入	224×224
优化器	AdamW, 10^{-3} , wd 10^{-4}
Batch	64
Epoch	5
训练对	11,188
验证准确率	98.34%

术语与文档。 M1：端到端 RTT；M2：有效上传率；M3：重采率；M5：Spearman 相关。网关环境变量见 `docs-zh/paper1/V19/ENV.md`。学习手册 `docs-zh/paper1/study/`（六章）与 `REPRODUCE.md` 提供复现步骤。

版本、校验与伦理。 2026-05-30：ROI + 真实 B3 纳入附录与正文。提交前应对 `b3_mobilenet.pt` 记录 SHA256。LangGraph 三支与正文 Algorithm 2 一致；JSONL 字段见补充材料。公开数据集仅离线使用；不写入患者标识。

性能与故障排查。 全矩阵在 CPU 上约 10 分钟（不含 B3 训练）；B3 训练约 45 分钟。缺权重时检查 `b3_use_learned` 与 `.venv` 中的 PyTorch 安装。

附录说明。 本附录支撑审稿人快速核对超参与延迟假设，无需通读全部源码。

C 符号说明

D 补充实验与工程细节

跨队列相关（M5）。 在完整 ShezhenV3 验证集（ $n=1,144$ 清晰/模糊对）上， Q_{img} 与二值标签的 Spearman 相关系数为 $\rho=0.363$ （`cross_tcm_fd.csv`）。低于合成阶段 2（ $\rho \approx 0.75$ ），但平均意义下仍单调可分； τ 标定采用组中位数而非假设分数区间不交。

Table 15: 延迟模型分量 (毫秒)。

分量	取值
采集	5.0
Edge-IQA	$\mathcal{N}(9, 2^2)$
路由	1.5
重采	p50 $\approx$ 50
上云	$\mathcal{U}(50, 550)$
B3 额外	+15-40 (CPU 量级)

Table 16: 主要符号与指标。

符号	含义
Q_{img}	Edge-IQA 质量分数, $[0, 1]$
τ_{B2}	舌区 ROI 路由阈值 (主矩阵; 0.465)
τ_{full}	全图标定阈值 (0.498)
τ_{B3}	学习 IQA 阈值 (0.5)
K	最大边缘重采次数
M1	端到端 RTT (报告 p50/p95)
M2	有效帧率 (路由后 $Q_{\text{img}} \geq \tau$)
M3	重拍率 (至少一次重采)
M5	验证集清晰/模糊对的 Spearman ρ

Franka 辅轨 (M6)。执行栈上 50 次闭环试验生成图 S1; 本地回路延迟不含模拟上云, 不得与表 11 数值直接对比。

可复现性。数据集导入、 τ 标定、矩阵回放与作图由 `scripts/paper1_run_tcm_full.sh` 编排, 路径见 `experiments/configs/tcm_paths.yaml`。

分数重叠与标定策略。真实 ShezhenV3 验证对存在分数重叠: 清晰组的最小 Q_{img} 可能低于模糊组的最大 Q_{img} 。原因是舌象纹理与苔质在轻度失焦下仍贡献 Laplacian 能量。因此同时报告组中位数与 Spearman ρ , 不假设完全可分簇。 τ 取两组中位数的中点, 并限制在 $[0.45, 0.65]$; 协议与阶段 2 一致, 但以 572 张真实清晰图及成对模糊替代合成直方图。

部署含义。尽管存在重叠, B2 在测试矩阵上的 M2 仍为 0.604 (物理重采, 3 seeds), 因为闭环重采与真实分数结合, 仍可在 $K=2$ 内越过 τ 。运维人员可查阅 JSONL 中的 `flags` 诊断失败原因, 无需检查原始云上传内容。

与合成阶段 2 的对比。合成标定: $\tau=0.505$, 中位数 0.819/0.191; ShezhenV3: $\tau=0.498$, 中位数 0.564/0.431, M5 $\rho=0.47$ (合成约 0.75)。真实纹理使 Q_{img} 整体下移, 但 B2 相对 B0/B1 的路由收

Table 17: 从合成阶段 2 到 ShezhenV3 全量验证的演进。

量	合成 (阶段 2)	ShezhenV3 (全量)
标定 n	240	1,144
清晰/模糊中位数	0.819 / 0.191	0.516 / 0.414 (ROI)
τ	0.505	0.465
M5 Spearman ρ	≈ 0.75	0.363
每 seed 测试帧	500 (仿真 Q)	500 (真实分数)
B2 M1 p50 (ms)	364.7	208.3
B2 M2 有效帧率	0.988	0.604

益在测试集上保持, 支持架构在玩具数据之外的外部有效性。

D.1 学习型 IQA 基线 B3 (MobileNetV3-Small)

基线 B3 使用在 ShezhenV3 `train` 划分上真实训练的 MobileNetV3-Small 二分类器, 取代此前对 Q_{img} 的 +0.08 仿真加成。在 ROI 裁剪后的舌象 patch 上微调 ImageNet 预训练权重, 输出 $Q_{\text{img}} = P(\text{clear} | I)$ 。

训练协议。对 5,594 张训练图 (其中 5,404 张含 COCO 框) 各生成两个样本: (i) 清晰 ROI (标签 1); (ii) 同 patch 经 $r \sim \mathcal{U}(2.5, 5.0)$ 高斯模糊 (标签 0)。输入尺寸 224 $\times$ 224; 优化器 AdamW (lr=10⁻³); batch 64; 训练 5 个 epoch (CPU, 可选 CUDA)。数据增强包括水平翻转及轻度亮度/对比度抖动 (仅训练集)。权重保存于 `experiments/results/b3_mobilenet.pt`; 推理封装于 `edge_iqa/learned_b3.py`。

主矩阵结果。在 $\tau_{B2}=0.465$ 下, B3 (MobileNet) 的 M2 为 0.934, 高于 B2 的 0.604; B3t ($\tau_{B3}=0.5$) 的 M2 为 0.929, 混合 B4 的 M2 为 0.936 (见表 11、表 12)。B2 仍是首选部署路径: M1 p50 最低 (208.3ms, 3-seed 均值), 且 `flags` 可审计。学习型头适合对有效帧率要求更高、可接受额外边缘算力的场景。

迁移解读。真实纹理使 Q_{img} 绝对值下降; Spearman 降低是因为清晰/模糊组重叠增大 (见 §5.2)。B2 仍保持并略强化有效帧优势, 且相对 B0 改善了 RTT 中位数, 说明路由架构可超出合成直方图泛化。ROI 与学习型 B3 已在正文中实现 (§4.8、§D.1); 后续可探索 ROI 与混合 flag 规则的组合。

JSONL 审计样例。补充材料 Listing 1 为 Franka 辅轨的脱敏 JSONL 行, 字段与 §4.10 一致:

Table 18: 边侧网关端点 (Paper I)。

方法	路径	用途
POST	/api/v1/vision/evaluate	上传图像并执行 Edge-IQA
POST	/api/v1/motion/skills/go_to_tongue_pose	舌位 skill
POST	/api/v1/motion/skills/go_to_face_pose	面位 skill
POST	/api/v1/motion/move_joints	关节 PTP
GET	/api/v1/status/joints	关节状态快照

Table 19: 环境变量 (franka_api_server)。

变量	默认	作用
PAPER1_ROOT	doctor/paper1	IQA 与 LangGraph 根路径
PAPER1_MODE	false	禁用 controller 路由
PAPER1_IQA_SUBPROCESS	true	子进程调用 scorer
PAPER1_VISION_THRESHOLD_TAU	0.55	JSON 缺失时的回退 τ
FRANKA_API_PORT	8000	监听端口

```
{
  "trial_id": 1,
  "q_img": 0.8075,
  "flags": [],
  "retry_count": 0,
  "route_decision": "upload_cloud",
  "latency_ms": 15.89
}
```

完整日志另含 ISO 8601 时间戳，由 validate_jsonl.py 校验。

算力预算。全验证打分 (1,144 对) 加三 seed 主矩阵，在笔记本 CPU 上可在十分钟内完成，便于新 TCM 批次到达后频繁重标定。

E 实现细节

本节记录边侧网关接口与 ShezhenV3 全量验证的离线实验驱动，便于第三方在不通读整个 monorepo 的情况下复现结果。

E.1 边侧网关 API

表 18 列出 franka_api_server 的 Paper I HTTP 端点；启用认证时需携带 X-API-Key 请求头。

Vision 接口契约。网关以子进程调用 edge_iqa.cli，PYTHONPATH 指向 doctor/paper1。响应包含 q_img、flags、t_iqa_ms，以及 recommended_tau.json 中的 threshold_tau。子进程隔离可避免 NumPy/PIL 阻塞 rclpy 执行器。

E.2 环境与配置

表 19 为常用环境变量；Paper I 实验设 PAPER1_MODE=1，以禁用与采集无关的阻抗/碰撞路由。

E.3 离线实验驱动

ShezhenV3 验证的推荐顺序为：(1) import_shezhenv3.py (写入 bboxes)；(2) 可选 train_b3_mobilenet.py；(3) calibrate_tau_tcm.py (ROI)；(4) roi_ablation.py；(5) run_matrix_tcm.py (B2 Edge-IQA + B3 学习分数)；(6) 图表与 L^AT_EX 生成。一键脚本 paper1_run_tcm_full.sh 链式调用上述步骤并编译 PDF。

E.4 ROI 与 B3 模块

coco_roi.py 实现并集框 + padding 裁剪；scorer.py 与 learned_b3.py 共用 ROI 逻辑。B3 权重为 b3_mobilenet.pt，验证准确率 98.34% (1144 对)。

矩阵打分。每测试帧预计算 q_b2 与 q_b3；B0-B2 使用 Edge-IQA 分数，B3 使用学习概率，避免重复 uplift 被重复计入。

目录与 CI。主要目录：edge_iqa/、langgraph_router/、experiments/splits|results|edge_iqa/、latex/、franka_api_server/。CI 运行单元测试；全量 ShezhenV3 验证为本地文稿目标，步骤见 REPRODUCE.md。修改 ROI padding 或 Edge-IQA 权重后，须重跑 orchestrator 再更新表 II。

数据集路径。Windows 路径 D:\...\shezhenv3-coco 在 WSL 下映射为 /mnt/d/...，仅需修改 tcm_paths.yaml 中的 dataset_root。test_scorer.py、test_routing.py 可在无 TCM 数据挂载的 CI 环境运行。

E.5 开放科学工件索引

表 20 索引 ShezhenV3 全量验证主要产出文件（路径相对 franka_ros2 根目录）。

无 FR3 硬件亦可仅依赖 TCM 挂载与 Python 环境复现表 11；Franka 辅轨为可选。

E.6 部署清单与操作流程

诊前标定。(1) 通过 import_shezhenv3.py 导入 ShezhenV3 或本地划分；(2) 启用 ROI 运行 calibrate_tau_tcm.py，将 recommended_tau.json 部署至边缘网关；(3) 可选：在具备 GPU/NN 运行时的节点上训练 B3；(4) 合并日志前，用 validate_jsonl.py 校验 JSONL 模式。

Table 20: 开放科学工件索引 (Paper I, TCM 全量运行)。

工件	路径
数据集划分	doctor/paper1/experiments/splits/tcm*.json
τ 标定	recommended_tau.json
验证集分数	calibration_val.csv
主矩阵明细	main_seed*_detail.csv
Table II	table_ii.json
M5 相关	cross_tcm_fd.csv
图表	figures/fig_iqa_hist.pdf 等
一键脚本	scripts/paper1_run_tcm_full.sh
英文 PDF	latex/main.pdf
中文 PDF	latex/main-zh.pdf

运行参数。环境变量 PAPER1_VISION_THRESHOLD_TAU 可覆盖 JSON 中的 τ ; use_roi 默认为 true; 重采预算 $K=2$; Edge-IQA 固定 512 缩放以保证延迟稳定。

操作员可读标志。blur 提示患者保持静止并重新张口; underexposed/overexposed 建议调整环光后再调用 FR3 技能。日志保留 q_img、路由决策与重试次数; 拒帧不必上传云端。

硬件分级。**A 级(纯 CPU 网关):**B2 + LangGraph, IQA p95 约 10 ms。**B 级(GPU 边缘):**可选 B3, 以部分可解释性换取更强的模糊排序。**C 级(Franka 辅轨):**M6 RTT, 不与表 II 的离线矩阵直接数值对比。

多中心部署。各中心应在本地验证批 (≥ 200 清晰/模糊对) 上重标定 τ , 且 scorer 代码须与主仓保持一致。光照差异会导致 τ 漂移; 报告应同时给出本地与 ShenzhenV3 全局中位数。

安全与隐私。图像在 upload_cloud 之前留于边缘; API Key 保护运动与视觉接口。去标识 JSONL 不含患者元数据; IQA 路径仅使用几何框, 不使用诊断标签。

与 MoveIt 技能集成。具名位姿 (tongue_pose、face_pose) 将采集几何与 IQA 解耦; 可在最终舌采前于 face_pose 做预检。

回归测试与文档。单元测试覆盖 flags 推导; 全矩阵回归见 paper1_run_tcm_full.sh (含 B3 训练时约 10–60 分钟)。英文文档 docs/、中文学习手册 docs-zh/paper1/study/ (六章) 与 REPRODUCE.md 构成新人上手路径。

E.7 失效模式与代表案例

ROI 后仍存在分数重叠。表 3 显示, 全图与 ROI 的「最小清晰减最大模糊」分离度均为负。典型情况: 全图中颊部边缘清晰导致 S 偏高, 而舌面已虚焦; ROI 可缓解但无法消除重叠, 因为苔质纹理在轻度散焦下仍具较高 Laplacian 能量。

B3 与 B2 的路由差异。MobileNetV3-Small 在 ROI 上训练后, 验证准确率 98.3%。全量矩阵中, B3 在 τ_{B2} 下 M2 为 0.934, B2 为 0.604 (物理重采, 见表 12)。学习概率与可解释 Q_{img} 的标度不一致; 若对 B3 单独重标定 τ , 可缩小差距, 但会引入第二套阈值工件。因此 B2 仍是首选部署路径, B3 作为可选的学习型对比。

合成模糊与临床运动。验证模糊采用高斯核 $r \in [2.5, 5.0]$, 而真实微动多为方向性拖影; Spearman ρ 约 0.36–0.47 反映了这一域差距。

缺框回退与延迟离群。部分训练图无 COCO 标注时, ROI 回退全图; 标定元数据记录 n_with_bbox。B3 的 CPU 推理增加每帧耗时; 表 II 中 B3 的 p95 RTT 相对 B2 上升, 与更重评分一致。

操作缓解与审计。重复 resample_edge 时, 应检查 JSONL 中的 flags; 若同时出现 blur 与曝光异常, 优先调整光照。Edge-IQA 具有确定性, 任意 JSONL 行可用 compute_q(..., use_roi=True) 离线复核路由决策。

小结。ROI 聚焦解剖区; B3 可学习模糊排序, 但需独立 τ 方能与 B2 的路由表现对齐。分数重叠与合成模糊仍是主要残余风险。

E.8 算例: 单帧经 B2 路由

设某测试图经 ROI 裁剪后, Edge-IQA 得 $Q_{\text{img}}=0.53$, $\tau=0.465$, 首次打分即通过。同一张原图经 $r=3.2$ 模糊后, $Q_{\text{img}}=0.38$, flags=[blur], LangGraph 选择 resample_edge; 经物理 Skill 重采后, 多数重试可越过 τ , 与 B2 聚合 M2= 0.604 一致。

B3 同帧对比。学习型分数在清晰 ROI 上 $P(\text{clear}) \approx 0.91$, 模糊 ROI 上 ≈ 0.42 (示意值)。若与 B2 共用 τ , 模糊帧仍可能路由失败——这有助于理解 B3 在共享阈值下的行为差异。

JSONL 片段（示意）。

```
{"q_img":0.53,  
  "route_decision":"upload_cloud"}  
{"q_img":0.41,"flags":["blur"],  
  "route_decision":"resample_edge",  
  "retry_count":1}
```

与 B0 对比。 B0 对模糊帧仍上云且 valid= 0，将 M2 拉低至 0.56。

操作员提示。 可将 blur 映射为「请保持静止，系统将自动重拍」。

小结。 本算例将微观分数与表 II 的宏观指标联系起来，且无需真实 FR3 硬件。

F 单栏参考表

Table 21: 多种子表 II 完整分解 ($\tau=0.465$)。

Seed	基线	M1 p50	M1 p95	M2	M3
0	B0	364.9	659.8	0.568	0.000
0	B2	211.1	527.0	0.610	0.432
0	B3	336.7	609.6	0.944	0.474
1	B0	378.0	656.8	0.556	0.000
1	B2	205.6	524.6	0.602	0.444
1	B3	347.6	601.0	0.938	0.480
2	B0	379.1	654.0	0.556	0.000
2	B2	208.3	529.1	0.600	0.444
2	B3	352.6	609.8	0.920	0.488

Table 22: 工件路径索引。

工件	路径
划分 JSON	experiments/splits/tcm_*.json
τ	recommended_tau.json
ROI 消融	roi_ablation.json
B3 权重	b3_mobilenet.pt
表 II	table_ii.json

复现与版本。 `paper1_run_tcm_full.sh` 可一键执行；分步说明见 `REPRODUCE.md`。中文学习手册六章见 `docs-zh/paper1/study/`。2026-05-30 版本纳入 ROI 与真实 B3。单栏表便于印刷版快速查阅数字，与正文双栏叙述互补。