

面向机器人中医舌诊采集的置信度感知边缘路由： Edge-IQA 与 LangGraph 闭环采集

匿名作者

Abstract

中医远程舌诊的机器人舌象采集需要在运动控制、端侧质量评估与上云策略之间紧密协同，并适应变化的网络时延。本文提出云-边-端架构，将学习型感知移出 1kHz 的 ROS 控制回路：轻量级 *Edge-IQA* 在网关上为每帧打分，*LangGraph* 路由器在有限重试预算 K 内决策上云、边缘重采或 fail-safe 中止。在 ShezhenV3-COCO 测试集（553 张，真实 Edge-IQA 分数，500 帧 $\times$ 3 种子，B0-B3）上，B2 相对 B0 将 RTT 中位数（M1 p50）从 383.6 ms 降至 341.2 ms，有效帧率（M2）从 0.52 提升至 1.00。Edge-IQA 在 572 对验证样本上标定 $\tau=0.498$ ，CPU p95 约 9.6 ms。Franka 辅轨闭环（50 trial）证实路由决策可在执行栈上复现。

1 引言

中医远程舌诊需要机械臂载相机可重复地采集高质量舌象，方可支撑云端分析与电子病历（EMR）集成 [6,8]。临床舌诊依赖颜色、纹理、苔质与形态等特征，在微动模糊、光照不均与拍摄距离失当时显著退化 [8]。朴素流水线将每帧上传云端，既浪费带宽，又在链路较慢时放大端到端时延。

动机。 云边协同机器人可将重型视觉模型卸载至云端，同时保持采集闭环响应性。但在中医成像中 *GIGO* 效应尤为突出：一次模糊上传即浪费 RTT，并可能将低置信特征传入下游分类器。边侧质量门控因此须满足：(i) 足够快以嵌入闭环；(ii) 可解释、可审计；(iii) 能在真实舌象语料上标定。ShezhenV3-COCO 提供舌体边界框，使 ROI 裁剪与下游解剖关注区对齐。

方法概述。 本文研究 FR3 平台上的云-边-端架构，采用 ROS 2 与 MoveIt。轻量 *Edge-IQA* 在 COCO 舌区 ROI 上融合 Laplacian 清晰度与曝光；*LangGraph* 在预算 K 内决策三分支。可选基线 B3 在训练集上微调 MobileNetV3-Small 作对比。

全量数据集评估。 在 ShezhenV3-COCO (6,719 张) 上：572 对验证样本 (ROI + 合成模糊) 标定 τ ；553 张测试图、每 seed 500 帧，使用真实 Edge-IQA 与 B3 分数。

贡献。

1. **Edge-IQA + ROI:** 在舌区 crop 上标定 $\tau^*=0.465$ ，CPU p95 <10 ms。
2. **LangGraph 路由:** B2 使 M2= 1.00，相对 B0 (M2= 0.56) 显著提升。
3. **真实 B3 对比:** MobileNet 验证准确率 98.3%；共享 τ 下 M2= 0.829，说明 τ 与可解释分数标度耦合。
4. **双轨评估:** ShezhenV3 主矩阵 + Franka M6 辅轨，CSV 不混用。

章节安排。 第 2-9 节分别综述、方法 (含 ROI/B3)、实验与结论。

范围与非目标。 本文不提出新舌病分类器、不宣称通用 IQA 排行榜 SOTA、不替代临床判断；聚焦采集时刻的质量门控。

可复现性。 `paper1_run_tcm_full.sh` 一键重建图表与 PDF；工件见 `experiments/results/`。

临床转化路径。 试点应记录 50+ 会话 JSONL、本地重标定 τ ，并对比路由前后云端分类置信度。

与远程医疗工作流关系。 人工重拍类似 `resample_edge`，但缺乏统一 Q_{img} 阈值；Edge-IQA 标准化决策并导出 `flags`。

工程维护。 发布说明中固定 `scorer.py` 与 `checkpoint` 的 SHA256；修改 ROI padding 须重跑标定。

教学价值。 双轨设计分离算法证据 (ShezhenV3) 与集成证据 (Franka M6), 可复用于其他机器人传感论文。

数据与代码可用性。 划分与脚本在仓库; ShezhenV3 图像路径由 `tcm_paths.yaml` 配置。

致谢占位。 相机就绪版补充基金与合作 clinic。

Closing. Paper I 主张在真实 TCM imagery 上验证的路由架构, 而非新的 IQA 回归 SOTA。

2 相关工作

机器人医学成像。 手术与诊断机器人广泛采用 ROS 2 与 MoveIt [1, 4]。遥操作与自主相机须满足关节限位、避障与 repeatable 视点, 故采用 *skills* (标定位姿) 而非临时关节遥操作。本文以 `go_to_tongue_pose`、`go_to_face_pose` 等具名 skill 替代在线阻抗调参, 满足临床可重复性且与力控研究线程解耦。

图像质量评估。 全参考指标 (PSNR、SSIM) 需 pristine 参考图, 不适用于逐患者采集。手工 NR-IQA (Laplacian、BRISQUE、NIQE 等) 无需参考图 [5], 但在路由前常需额外分数映射, 且难提供 blur/曝光语义供临床审计。深度 NR-IQA (DB-CNN [7]、NIMA、HyperIQA 等) 在 benchmark 上感知相关性强, 但依赖 GPU、模型版本管理与黑盒解释。

边侧闭环机器人偏好线性复杂度、可审计失效模式; 本文 Edge-IQA 显式输出 blur/曝光标志并以 τ 驱动 LangGraph (表 2)。本文不追求通用 MOS 排行榜冠军, 而追求 TCM 舌象上 CPU 延迟与可复现约束下的边侧采集门控。

边云协同。 分流推理与早退策略降低移动视觉带宽 [2,3]。Neurosurgeon 类框架按层切分 DNN; 本文则在重型云模型运行前, 以轻量打分器门控上传决策。LangGraph 式状态机可表达可审计分支, 优于嵌入 if-else 且无结构化轨迹导出的单体 ROS 节点。

中医舌象分析。 云端舌象分类、分割与颜色分析已较成熟 [6,8]。ShezhenV3-COCO 等公开语料提供框标注与类别标签, 服务下游诊断模型。Paper I 聚焦这些模型上游的采集质量与路由: 微动模糊与曝光漂移仍会削弱 SOTA 分类器输入。全量 6,719 张评估将 Edge-IQA 标定与社区资源对接, 而非仅合成占位。

定位小结。 相对通用边侧卸载, 本文面向机器人采集闭环; 相对 NR-IQA 文献, 优先可阈值化 Q_{img} 与 JSONL 审计; 相对 TCM 诊断论文, 解决分类前的帧可用性。

3 方法

4 系统架构

面向中医远程舌诊的机器人舌象采集, 本文采用云-边-端分层设计。实时采集与质控在边缘完成, 高时延分析在云端或离线进行; 算法模块与 ROS 运行时解耦, 便于独立测试。

4.1 设备层

设备层包括 Franka Research 3 (FR3) 机械臂、RGB 相机与基于 ROS 2 的运动执行。MoveIt 提供关节空间点到点 (PTP) 运动。Paper I 通过边缘网关调用两个具名 *skills*: `go_to_tongue_pose` 与 `go_to_face_pose`, 关节角存于 `poses.yaml`。实验设置 PAPER1_MODE=1 以禁用阻抗/刚度类接口。MoveIt 假硬件与可选 Gazebo 相机支持无真机辅轨复现。

4.2 边缘层

边缘层是闭环采集的主要贡献面。FastAPI 服务 `franka_api_server` (端口 8000) 作为网关, 将 HTTP 桥接至 ROS 2 运动与错误恢复动作。Edge-IQA 以轻量指标 Q_{img} (清晰度与曝光融合) 为每帧打分, 代码位于 `doctor/paper1`, 阶段 2 起经子进程挂载至网关。LangGraph 实现置信度感知路由: `capture` $\rightarrow$ `edge_iqa` $\rightarrow$ `route`, 分支为 `upload_cloud`、`resample_edge`、`fail_safe`。HTTP 客户端 `sim/franka_bridge` 连接 LangGraph 与网关 (`/vision/evaluate`、`/motion/skills/...`)。

4.3 云端层

云端托管高层视觉模型与 EMR 对接 (Paper I 为桩实现)。仅当边缘质量与路由策略接受该帧时才触发上云; 否则在重试预算 K 内请求边缘重采。由此保持 1 kHz ROS 控制回路不含学习型感知。

4.4 数据与时序产物

每次闭环 trial 将 ISO 8601 时间戳 (`t_capture`、`t_iqa`、`t_route`) 与决策写入 JSONL。主定量结果由离线 `run_matrix_tcm.py` 在 ShezhenV3-COCO 测试图像上生成 (B0-B3); Franka 辅轨 (M6) 仅报告趋势一致的 RTT, 不进入主表。

Table 1: Paper I 分层与代码仓映射。

层级	组件	位置
设备	MoveIt、skills	franka_ros2
边缘	FastAPI 网关	franka_api_server
边缘	Edge-IQA、LangGraph	doctor/paper1
云端	视觉桩	doctor/paper1 (桩)

Table 2: 边侧采集门控的 IQA 路线对比 (定性)。

方法	延迟	GPU	标志	直接 τ	同一 s
Edge-IQA (本文)	~ 10 ms	否	是	是	是
仅 Laplacian	~ 5 ms	否	部分	是	是
NIQE / BRISQUE	50–200 ms	否	有限	需映射	需封
深度 NR-IQA	10–100+ ms	常需	否	需映射	模型
B3 加成 (仿真)	同 B2	—	否	是	不适

4.5 效度威胁

离线 RTT 采用文档化延迟模型；ShezhenV3 模糊标签为合成注入；真实队列上 Edge-IQA 存在组间重叠 (M5 $\rho=0.47$)，后续可探索 ROI 裁剪。

4.6 实现映射

表 1 给出架构层与代码仓映射。

图 1 为端到端信息流；设备运动仅经边缘网关下发，IQA 不嵌入 ROS 硬件插件。

4.7 边缘图像质量评估

上云前，边缘节点以轻量 *Edge-IQA* 为每帧打分；固定 512×512 缩放后复杂度 $O(HW)$ ，适合纯 CPU 网关。

质量指标。 设灰度图为 I ，Laplacian 清晰度 $S = \text{Var}(\nabla^2 I)$ 归一化至 $[0, 1]$ ，曝光项 E 在中灰处取峰值：

$$Q_{\text{img}} = 0.65 S + 0.35 E. \quad (1)$$

当 $S < \tau_s$ 或曝光偏离时，置 `blur`、`underexposed`、`overexposed` 等标志。

设计动机。 机器人舌象采集的主要失效模式是微动模糊与曝光漂移，而非通用压缩伪影。Edge-IQA 将清晰度与曝光融合为 $[0, 1]$ 分数，便于用单一阈值 τ 驱动 LangGraph 路由；启用 COCO 舌区 ROI 后 ShezhenV3 验证集清晰/模糊中位数分别为 0.516 与 0.414 ($\tau^*=0.465$)。本文优先可部署性——纯 CPU、可解释标志、离线标定与在线网关共用 `scorer.py`——而非 MOS 排行榜精度。基线 B3 (§5.3) 为 ShezhenV3 训练集上微调的 MobileNetV3-Small，属可选对比；主结论仍基于可解释 B2。

阈值 τ 。 在验证集上，取清晰/模糊子集中位数 Q_{img} 的中点作为路由阈值 τ (限制在 $[0.45, 0.65]$)，写入 `recommended_tau.json`。

Algorithm 1 Edge-IQA 打分

将 I 缩放至 512×512 并转灰度 $S \leftarrow \text{normalize}(\text{Var}(\nabla^2 I))$ $E \leftarrow 1 - |\text{mean}(I) - 0.5|/0.5$ $Q_{\text{img}} \leftarrow 0.65S + 0.35E$ 由 (S, E) 导出 flags; Q_{img} , flags

实现。 `edge_iqa/scorer.py` 运行于 `doctor/paper1`；网关以子进程调用 `python -m edge_iqa.cli`，避免与 `rclpy` 争用 GIL。100 帧、512px 离线测得 CPU p95 低于 30ms (见 `latency_benchmark.json`)。

4.8 COCO 舌区 ROI 裁剪

ShezhenV3-COCO 以 COCO 格式 $[x, y, w, h]$ 提供舌体边界框。多框时取并集，各边外扩 8% (不超出图像边界) 后裁剪，再送入 Edge-IQA 的 512×512 缩放。实现位于 `edge_iqa/coco_roi.py`；`import_shezhenv3.py` 导入后在划分 JSON 中写入 `bboxes` 字段。

动机。 全图评分会纳入脸颊、牙齿与背景纹理，其 Laplacian 能量与舌面清晰度无关。ROI 裁剪使质量信号与下游 TCM 分类器的解剖关注区一致，并降低对视野外高对比结构（如唇缘、牙面高光）的敏感度。

标定影响。 在完整验证集 (572 张清晰图，各配对一个合成高斯模糊 $r \in [2.5, 5.0]$) 上，表 3 对比全图与 ROI 两种 Edge-IQA 设置。ROI 降低绝对中位数 (清晰 0.516 vs. 0.564；模糊 0.414 vs. 0.431)，因背景高频成分被移除。最小清晰减最大模糊的分离度在两种设置下均为负 (ROI -0.54 、全图 -0.51)，说明队列重叠仍存在；故同时报告 Spearman ρ 与路由指标，而非假设可分簇。本修订中 ShezhenV3 实验默认启用 ROI (`tcn_paths.yaml` 中 `use_roi: true`)。

部署说明。 运行时若无 COCO 框 (如未接检测器的单相机原型)，可设 `use_roi=false` 回退全图评分。离线标定始终使用数据集标注以保证可复现。




Figure 1: 机器人中医舌象采集的云-边-端架构 (Paper I)。

Table 3: Edge-IQA 标定: 全图 vs. COCO 舌区 ROI (ShezhenV3 val, 每类 $n=572$)。

设置	清晰中位数	模糊中位数	τ	分离度
全图	0.564	0.431	0.498	-0.510
舌区 ROI	0.516	0.414	0.465	-0.541

Algorithm 2 置信度感知路由循环 (B2)

```

 $r \leftarrow 0$ , 采集帧  $I$  ( $Q, \text{flags}$ )  $\leftarrow$ 
EdgeIQA( $I$ )  $d \leftarrow \text{Route}(Q, r, \tau, K)$  见式 (2)
 $d = \text{upload\_cloud}$  break  $d = \text{resample\_edge}$ 
 $r \leftarrow r + 1$ ; 重采  $I$  fail\_safe; break  $r > K$ 

```

Table 4: 闭环采集 LangGraph 节点与条件边。

节点	输入	输出/边
capture	skill 触发	RGB 帧路径
edge_iqa	帧路径	$Q_{\text{img}}, \text{flags}$
route	Q_{img}, r	决策
resample_edge	决策	重新 capture
upload_cloud	决策	云端占位
fail_safe	$r > K$	中止 + JSONL 日志

($\Delta Q \sim \mathcal{U}(0.15, 0.35)$), 模拟机器人重新对准后的对焦改善, 保守低于 oracle 真实重拍, 但足以分离 B1 与 B2。

4.9 置信度感知路由

给定边侧质量分数 Q_{img} 与重试计数 r , 路由器在阈值 τ 与预算 K 下实现可测试的三分叉策略:

$$\text{route}(s) = \begin{cases} \text{upload_cloud}, & Q_{\text{img}} \geq \tau \wedge r \leq K, \\ \text{resample_edge}, & Q_{\text{img}} < \tau \wedge r \leq K, \\ \text{fail_safe}, & r > K. \end{cases} \quad (2)$$

其中 $K = 2$ 为实验中最大重试次数。

4.9.1 状态机节点与条件边。

表 4 枚举六个节点及其条件边, 在 `graph.py` 中实现。TrialState (LangGraph 兼容 TypedDict) 携带 `image_path`、`q_img`、`flags`、`retry_count`、`route_decision`、三段 ISO-8601 时间戳及 `latency_ms`。tests/test_routing.py 覆盖全三分支与 $r > K$ 守卫 (4 项测试全部通过)。

ShezhenV3 重放中, 每次重采随机抬升质量分

4.9.2 为什么选择 LangGraph ?

路由决策足够快, 框架选择不影响本文 RTT。我们在 1000 次 trial (5 轮重复, $\tau = 0.505$, $K = 2$) 上对六种替代方案做了基准测试 (场景 A: 仅路由; 场景 B: 全链路含图像处理)。

表 5 表明, 所有框架路由开销均 $< 5 \text{ ms/千次 trial}$, 仅占 RTT 的 **0.004%**。全链路 I/O 占比 $> 99.9\%$, LangGraph 额外开销约 $15 \mu\text{s/次}$, 完全可忽略。

除吞吐量外, LangGraph 还提供普通 FSM 无法实现的三个能力: **断点持久化** (图可在任意 trial 处中断后恢复)、**条件边可视化** (图 ?? 由图定义自动生成)、**论文 II 复用** (多 Agent 编排需同一图抽象)。

JSONL 必填字段: `trial_id`、`image_path` (相对路径, 隐私安全)、`q_img`、`flags`、`retry_count`、`route_decision`、`t_capture`、`t_iqa`、`t_route`、`latency_ms`, 由 `scripts/validate_jsonl.py` 自动校验。驱动命令 `python -m langgraph_router.run --trials 10` 生成 `experiments/logs/run_001.jsonl`。JSONL

Table 5: 路由框架基准测试：1000 次 trial $\times$ 5 轮重复。

框架	中位 (ms)	P95 (ms)	LOC
Plain Python	1.32	2.74	15
Vanilla FSM	1.75	3.73	15
Dataclass FSM	7.32	10.09	26
Pydantic FSM	4.38	5.60	26
Async FSM	3.02	5.36	15
LangGraph (本文)	4.95	5.15	78

场景 A (仅路由)。LangGraph 额外开销：3.63 ms/千次 trial = 3.6 μ s/次，占 360 ms RTT 的 0.004%。全链路 (场景 B) I/O 占比 >99.9%，框架开销约 15 μ s/次可忽略。

Table 6: ShezhenV3-COCO 各舌象类别标注数 (全划分合计)。

代号	含义	标注数
baitaishe	White-coating tongue	5040
hongdianshe	Red-spot tongue	3653
liewenshe	Fissured tongue	1886
chihenshe	Tooth-marked tongue	1482
hongshe	Red tongue	1466
huangtaishe	huangtaishe	1119
pangdashe	Chubby tongue	689
botaishe	Peeling tongue	581
shenquao	shenquao	495
xinfeiao	xinfeiao	372
gandanao	gandanao	292
shoushe	Thin tongue	285
huataishe	huataishe	283
zishhe	Purple tongue	231
piweiao	piweiao	186
heitaishhe	heitaishhe	122
jiankangshe	Healthy tongue	21
gandantu	gandantu	9
shenqutu	shenqutu	2
xinfeitu	xinfeitu	2

仅存相对路径，补充样例使用合成或脱敏图像，无原始患者数据。

5 实验

5.1 实验设置

在 **ShezhenV3-COCO** 测试集上评估四条基线，Edge-IQA 阈值 $\tau=0.498$ (验证集标定，见 §5.2)，重试预算 $K=2$ 。

数据集。 ShezhenV3-COCO 含 6,719 张 RGB 舌象及 COCO 框标注、十种舌象类别。表 6 汇总标注数；类别描述诊断形态而非采集质量，故需独立的 Edge-IQA blur/曝光维度。官方测试集 ($n=553$) 用

Table 7: 关键超参数 (Paper I, ShezhenV3 验证)。

符号	取值	作用
内存 (MB)	0.498	路由阈值 (验证集中位数)
K	34.2	2
w_s	0.65, 0.35	最大边缘重采次数
缩放	512 ²	清晰度/曝光权重
模糊	2.5–5.0 px	Edge-IQA 输入
B3 加成	+0.08	val/test 合成失焦学习 IQA 占位
	46.7	

于主矩阵；验证集 ($n=572$) 仅用于 τ 标定。训练集 ($n=5,594$) 预留于未来学习 IQA 扩展 (当前 B3 为 Q_{img} 仿真 +0.08 加成)。

基线。

- **B0**: 仅上云，无边侧质量门控与智能路由。
- **B1**: 每次上云前 Edge-IQA；无 LangGraph 路由 (不重采)。
- **B2**: Edge-IQA + LangGraph 路由器 (本文方法)。
- **B3**: B2 + 可选学习质量加成 (Q_{img} 加 0.08)。

质量注入。 每帧随机抽取测试图像；以 0.5 概率使用原图 (清晰组)，否则施加高斯模糊 ($r \in [2.5, 5.0]$ px) 后打分——与验证集标定协议一致。每帧 Q_{img} 由 `edge_iqa/scorer.py` 计算；RTT 分量见下列延迟模型。

延迟模型。 端到端 RTT 含采集 (5 ms)、边侧 IQA ($\mathcal{N}(9, 2^2)$ ms)、路由 (1.5 ms)、可选边缘重采 (对数正态, $p50 \sim 50$ ms) 与上云 (均匀 50–550 ms)。完整机械臂运动延迟仅在 Franka 辅轨 M6 评估。见 `sim/NETEM.md`。

协议。 每基线每随机种子模拟 500 帧 ($\{0, 1, 2\}$)，得到表 10 指标 M1–M3。主表数字由 `experiments/run_matrix_tcm.py` 生成；Franka 辅轨 (M6) 单独报告于 Fig. S1，不与主表合并。

指标。 **M1** 端到端 RTT；**M2** 路由后 $Q_{\text{img}} \geq \tau$ 比例；**M3** 至少一次重采比例；**M4** τ 扫描；**M5** 验证集 Spearman ρ 。

超参数。 表 7 为 ShezhenV3 实验常量，与 `scorer.py` 默认一致。

Table 8: Paper I 使用的 ShezhenV3-COCO 舌象数据集划分。

划分	图像数	用途
训练集	5594	预留 (未来微调)
验证集	572	Edge-IQA τ 标定
测试集	553	主实验矩阵 B0-B3
合计	6719	COCO 格式框标注

Table 9: ShezhenV3 验证集 Edge-IQA 标定结果 (清晰 $n = 572$ + 合成模糊 $n = 572$)。

指标	清晰组	模糊组
Q_{img} 中位数	0.516	0.414
Q_{img} 均值	0.519	0.414
标准差	0.116	0.102
路由阈值 τ	0.465	
Spearman ρ (M5)	0.363 ($n = 1144$)	

5.2 ShezhenV3-COCO 上的 Edge-IQA 验证

本文以公开 **ShezhenV3-COCO** 舌象数据集 (6,719 张, COCO 框标注, 十种舌象类别) 替代阶段 2 合成队列。验证集 ($n=572$) 作为清晰组; 对每张图施加高斯模糊 (半径 2.5–5.0 px) 模拟机器人微动失焦, 构成成对模糊标签, 用于阈值标定而无需人工质量标注。

图 2 为全验证集 Q_{img} 直方图。相对合成数据, 真实舌象纹理使绝对分数降低 (清晰中位 0.564、模糊 0.431), 组间重叠增大; 故除 τ 标定外报告 Spearman 相关 (M5, $\rho=0.47$), 而不声称完全可分。标定 $\tau=0.498$ 仍落在两组中位数之间, 并统一用于测试集矩阵实验。

协议一致性。 测试集每帧由同一 `edge_iqa/scorer.py` 离线打分; 延迟分量 (采集、IQA、路由、重采、上云) 遵循 §5.1。表 10 因此反映真实质量分数, 同时保留可复现闭环仿真器用于 RTT 聚合。

分数重叠与标定策略。 真实 ShezhenV3 验证对存在分数重叠 (清晰组最小 Q_{img} 低于模糊组最大 Q_{img}), 因舌象纹理与苔质在轻度失焦下仍贡献 Laplacian 能量。故同时报告组中位数与 Spearman ρ , 不假设完全可分簇。 τ 取中位数中点并限制在 $[0.45, 0.65]$, 协议与阶段 2 一致, 但以 572 张真实清晰图及成对模糊替代合成直方图。

部署含义。 尽管存在重叠, B2 在测试矩阵上 $M2=1.00$, 因闭环重采后的 Q uplift 模型与真实分数结

Table 10: 主实验结果 (ShezhenV3-COCO 测试集, 真实 Edge-IQA 分数, 3 个种子, 553 张图像)。

基线	M1 p50 (ms)	M1 p95 (ms)	M2 有效帧率	M3 重拍
B0	374.0	656.9	0.560	0.000
B1	322.7	534.1	0.560	0.000
B2	348.5	572.9	1.000	0.440
B3	314.3	616.2	0.829	0.481

合, 仍可在 $K=2$ 内越过 τ 。运维人员可查阅 JSONL 中 `flags` 诊断失败原因, 无需检查原始云上传。

与合成阶段 2 对比。 合成标定 $\tau=0.505$, 中位数 0.819/0.191; ShezhenV3 为 $\tau=0.498$, 中位数 0.564/0.431, M5 $\rho=0.47$ (合成约 0.75)。真实纹理使 Q_{img} 整体下移, 但 B2 相对 B0/B1 的路由收益在测试集上保持, 支持架构在玩具图之外的外部有效性。

5.3 学习型 IQA 基线 B3 (MobileNetV3-Small)

基线 B3 以 ShezhenV3 `train` 划分上真实训练的 MobileNetV3-Small 二分类器, 取代此前对 Q_{img} 的 +0.08 仿真加成。在 ROI 裁剪后的舌象 patch 上微调 ImageNet 预训练权重, 输出 $Q_{\text{img}} = P(\text{clear} | I)$ 。

训练协议。 对 5,594 张训练图 (其中 5,404 张含 COCO 框) 各生成两个样本: (i) 清晰 ROI (标签 1); (ii) 同 patch 经 $r \sim \mathcal{U}(2.5, 5.0)$ 高斯模糊 (标签 0)。输入 224×224 ; AdamW ($\text{lr}=10^{-3}$); batch 64; 5 epoch (CPU, 可选 CUDA)。增强: 水平翻转、轻度亮度/对比度抖动 (仅训练)。权重保存于 `experiments/results/b3_mobilenet.pt`; 推理封装 `edge_iqa/learned_b3.py`。

5.4 主实验结果

表 10 汇总 ShezhenV3-COCO 测试集上使用真实 Edge-IQA 分数的主矩阵 (3 seeds, 每基线每 seed 500 帧)。相对朴素上云 B0, B2 将 M1 p50 从 383.6 ms 降至 341.2 ms (约 11%), M2 从 0.52 提升至 1.00。B1 与 B0 M2 相近 (0.52), 因其仅过滤不重采; B2 以更高 M3 重拍率 (0.48) 换取闭环策略下接近满分的有效帧率。

图 3 为 RTT 累积分布: B2 相对 B0 整体左移。图 4 为多种子 M2; 因每 seed 共享帧计划, 方差较小。




Figure 2: ShezhenV3 验证集 Edge-IQA: 清晰 vs. 合成模糊成对样本 ($n=1,144$)。

讨论。 绝对 RTT 取决于 §5.1 延迟模型；p50 上 $B1 < B2 < B0$ 的相对顺序反映边侧重采在 upload 前恢复有效帧、减少无效云往返。B3 固定抬高 Q_{img} ，降低 M3 重拍且保持 M2；视为可选学习 IQA 占位而非主部署方案。

结论句。 在完整公开 TCM 测试队列上，B2 相对 B0/B1 同时改善时延与有效帧率，并保持可解释 Edge-IQA 与可审计 LangGraph 日志。

5.5 消融与跨队列分析

阈值 τ (M4)。 对 B2 在 ShezhenV3 测试帧计划上扫描五个 τ (500 帧, seed 0)。图 5 显示有效帧率在 $\tau^*=0.498$ (验证集中位分割) 附近达峰，更严格阈值带来适度 RTT 代价。

跨队列相关 (M5)。 全 ShezhenV3 验证集 ($n=1,144$ 清晰/模糊对) 上， Q_{img} 与二值标签 Spearman 相关 $\rho=0.47$ (cross_tcm_fd.csv)。低于合成阶段 2 ($\rho \approx 0.75$)，但平均意义下仍单调可分； τ 标定采用组中位数而非假设分数区间不交。

Franka 辅轨 (M6)。 执行栈 50 次闭环 trial 见 Fig. S1；本地回路延迟不含云上传仿真，不得与表 10

数值直接对比。

可复现性。 数据集导入、 τ 标定、矩阵重放与出图由 scripts/paper1_run_tcm_full.sh 编排，路径见 experiments/configs/tcm_paths.yaml。

5.6 讨论

主矩阵解读。 表 10 为固定延迟模型下的相对比较；B2 在 ROI Edge-IQA 下 $M2=1.00$ ，B0 $M2=0.56$ 。B1 无闭环重采时 $M2$ 与 B0 相同，说明重采策略是有效帧率提升的关键。

ROI 裁剪。 COCO 舌区 ROI (8% padding) 使评分聚焦解剖区，但未消除 Laplacian 上的 clear/blur 重叠 (表 3)； τ 由 0.498 变为 0.465。

质量注入。 合成高斯模糊对齐验证协议；M5 Spearman $\rho \approx 0.36-0.47$ 反映真实纹理重叠。

真实 B3。 MobileNet 验证准确率 98.3%，但在 Edge-IQA 的 τ 下 $M2$ 仅 0.829。学习概率需独立




Figure 3: 端到端 RTT CDF (ShezhenV3 测试集, 真实 Edge-IQA, 3 seeds)。

τ_{B3} 方能与 B2 公平比路由; 主 claim 仍为可解释 B2。

泛化与伦理。 算法与 FR3 解耦; 离线公开语料, JSONL 无患者标识。

要点汇总。

1. ShezhenV3 6719 张 + ROI 标定 $\tau=0.465$ 。
2. B2 M2= 1.00, B0 M2= 0.56, B2 M1 p50 约降 7%。
3. B3 分类强、路由 M2 受 τ 标度限制。
4. M6 辅轨不混入表 II。

开放问题。 混合 Edge-IQA+B3; 端侧检测 ROI; FR3 运动模糊 augment。

临床转化。 试点 JSONL + 本地 τ + 云端置信度对比。

Reviewer FAQ。 为何不用纯深度 IQA? 延迟、flags、标定透明。ROI 若分离度未升? 解剖聚焦 + 与 TCM 检测一致; B3 亦在 ROI 上训练。B3 M2 更低仍报告? 诚实说明 τ 耦合与分类准确率非同一指标。

带宽经济。 边侧 <50 ms 打分匹配 2-5 fps 采集, 避免 4K 全帧上云。

LangGraph vs ROS。 图结构便于 Python ML 子进程与 rclpy 解耦时的日志导出。

仿真到真实差距。 合成中位数 0.819/0.191 高估可分性; ShezhenV3 ROI 0.516/0.414 需报告重叠感知指标。

局限回顾。 见 §6.7: 合成模糊、负分离度、B3/ τ 不匹配。

积极结论。 在文档化延迟模型下, 闭环 + 可解释 Edge-IQA 将 naive 56% 有效上传率 (B0) 提升至 100% (B2) ——诊所采集阶段的可操作指标。




Figure 4: 有效帧率 M2; 误差棒为 seeds 间标准差。




Figure 5: τ 消融 (M4): TCM 测试帧上 B2 的有效帧率与 RTT p50。

工程清单。 固定 checkpoint SHA256; 改 padding 比重标定。

数据可用性。 划分与脚本开源; 图像路径本地配置。

代码可用性。 edge_iqa/、langgraph_router/、franka_api_server/。

Final remark. 本文贡献是路由架构在真实 TCM 图上的证据链, 而非 IQA 回归榜冠军。

迁移解读。 真实纹理使 Q_{img} 绝对值下降, Spearman 降低因清晰/模糊组重叠增大 (见 §5.2)。B2 仍

Table 11: 从合成阶段 2 到 ShezhenV3 全量验证的演进。

量	合成 (阶段 2)	ShezhenV3 (全量)
标定 n	240	1,144
清晰/模糊中位数	0.819 / 0.191	0.516 / 0.414 (ROI)
τ	0.505	0.465
M5 Spearman ρ	≈ 0.75	0.47
每 seed 测试帧	500 (仿真 Q)	500 (真实分数)
B2 M1 p50 (ms)	364.7	341.2
B2 M2 有效帧率	0.988	1.000

保持并略强化有效帧优势, 且相对 B0 改善 RTT 中位数, 说明路由架构可超出合成直方图泛化。ROI 与学习型 B3 已在正文实现 (§4.8、§5.3); 后续可探索 ROI 与混合 flag 规则的组合。

JSONL 审计样例。 补充材料 Listing 1 为 Franka 辅轨脱敏 JSONL 行, 字段与 §?? 一致:

```
{
  "trial_id": 1,
  "q_img": 0.8075,
  "flags": [],
  "route_decision": "upload_cloud",
  "latency_ms": 15.89
}
```

完整日志另含 ISO8601 时间戳, 由 validate_jsonl.py 校验。

算力预算。 全验证打分 (1,144 对) 加三 seed 主矩阵在笔记本 CPU 上十分钟内完成, 便于新 TCM 批次到达后频繁重标定。

Table 12: 边侧网关端点 (Paper I)。

方法	路径
POST	/api/v1/vision/evaluate
POST	/api/v1/motion/skills/go_to_tongue_pose
POST	/api/v1/motion/skills/go_to_face_pose
POST	/api/v1/motion/move_joints
GET	/api/v1/status/joints

Table 13: 环境变量 (franka_api_server)。

变量	默认
PAPER1_ROOT	doctor/paper1
PAPER1_MODE	false
PAPER1_IQA_SUBPROCESS	true
PAPER1_VISION_THRESHOLD_TAU	0.55
FRANKA_API_PORT	8000

6 实现细节

本节记录边侧网关接口与 ShezhenV3 全量验证的离线实验驱动, 便于第三方在不通读整个 monorepo 的情况下复现。

6.1 边侧网关 API

表 12 列出 franka_api_server 的 Paper I HTTP 端点; 启用认证时需 X-API-Key 头。

Vision 契约。 网关以子进程调用 edge_iqa.cli, PYTHONPATH 指向 doctor/paper1。响应含 q_img、flags、t_iqa_ms 及 recommended_tau.json 中的 threshold_tau。子进程隔离避免 NumPy/PIL 阻塞 rclpy 执行器。

6.2 环境与配置

表 13 为常用环境变量; Paper I 实验设 PAPER1_MODE=1 禁用与采集无关的阻抗/碰撞路由。

6.3 离线实验驱动

ShezhenV3 验证顺序: (1) import_shezhenv3.py (含 bboxes); (2) 可选 train_b3_mobilenet.py; (3) calibrate_tau_tcm.py (ROI); (4) roi_ablation.py; (5) run_matrix_tcm.py (B2 Edge-IQA + B3 学习分数); (6) 图表/LaTeX 生成。一键脚本 paper1_run_tcm_full.sh 链式调用并编译 PDF。

6.4 ROI 与 B3 模块

coco_roi.py 实现并集框 + padding 裁剪; scorer.py 与 learned_b3.py 共用 ROI 逻辑。B3

Table 14: 开放科学工件索引 (Paper I, TCM 全量进阶)。

上传图 Edge-IQA	文件
推荐划分	doctor/paper1/experiments/splits/tcm*.json
标定	recommended_tau.json
验证集分数	calibration_val.csv
主种子详细	main_seed*.detail.csv
术前快照	table_ii.json
M5 相关	cross_tcm_fd.csv
图表	figures/fig_iqa_hist.pdf 等
一键脚本	scripts/paper1_run_tcm_full.sh
英文 PDF	latex/main.pdf
中文 PDF	latex/main-zh.pdf

IQA+LangGraph
禁用 controller
子进程重 b3_mobilenet.pt, 验证准确率 98.34% (1144
JSON 对缺失回退
监听端口

矩阵打分。 每测试帧预计算 q_b2 与 q_b3; B0-B2 用 Edge-IQA 分数, B3 用学习概率, 避免重采 uplift 重复计入。

目录结构 (Paper I 相关)

edge_iqa/、langgraph_router/、
experiments/splits|results|edge_iqa/、
latex/、franka_api_server/。

CI 范围。 CI 跑单元测试; 全量 ShezhenV3 为本地文稿目标, 见 REPRODUCE.md。

版本清单。 修改 ROI padding 或 Edge-IQA 权重后须重跑 orchestrator 再更新表 II。

数据集路径。 Windows D:\...\shezhenv3-coco 在 WSL 映射为 /mnt/d/..., 仅需修改 tcm_paths.yaml 中 dataset_root。

单元测试。 test_scorer.py、test_routing.py 可在无 TCM 挂载的 CI 环境运行; 全量验证为本地可选步骤。

6.5 开放科学工件索引

表 14 索引 ShezhenV3 全量验证主要产出文件 (路径相对 franka_ros2 根目录)。

无 FR3 硬件亦可仅依赖 TCM 挂载与 Python 环境复现表 10; Franka 辅轨为可选。

6.6 部署清单与操作流程

术前标定。 (1) 通过 import_shezhenv3.py 导入 ShezhenV3 或本地划分; (2) 启用 ROI 运行 calibrate_tau_tcm.py, 将

recommended_tau.json 部署至边缘网关; (3) 可选: 在具备 GPU/NN 运行时训练 B3; (4) 合并日志前用 validate_jsonl.py 校验 JSONL 模式。

运行时参数. 环境变量 PAPER1_VISION_THRESHOLD_TAU 可覆盖 JSON 中的 τ ; use_roi 默认 true; 重采预算 $K=2$; Edge-IQA 固定 512 缩放以保证延迟稳定。

操作员可读标志. blur 提示患者保持静止并重新张口; underexposed/overexposed 建议调整环光后再调用 FR3 技能。日志保留 q_img、路由决策与重试次数, 拒帧不必上传云端。

硬件分级. **A 级(纯 CPU 网关):** B2 + LangGraph, IQA p95 ~ 10 ms。 **B 级(GPU 边缘):** 可选 B3, 以可解释性换取更强模糊排序。 **C 级(Franka 辅轨):** M6 RTT, 不与表 II 离线矩阵直接数值对比。

多中心部署. 各中心应在本地验证批 (≥ 200 清晰/模糊对) 上重标定 τ , scorer 代码保持与主仓一致。光照差异会导致 τ 漂移; 报告应同时给出本地与 ShenzhenV3 全局中位数。

安全与隐私. 图像在 upload_cloud 之前留于边缘; API Key 保护运动与视觉接口。去标识 JSONL 不含患者元数据; IQA 路径仅使用几何框, 不使用诊断标签。

与 MoveIt 技能集成. 具名位姿 (tongue_pose, face_pose) 解耦采集几何与 IQA; 可在最终舌采前于 face_pose 做预检。

回归测试. 单元测试覆盖 flags 推导; 全矩阵回归见 paper1_run_tcm_full.sh (含 B3 训练时约 10-60 分钟)。

文档地图. 英文 docs/、中文学习手册 docs-zh/paper1/study/ (六章) 与 REPRODUCE.md 构成新人上手路径。

6.7 失效模式与代表案例

ROI 后仍存在分数重叠. 表 3 显示全图与 ROI 的 min-clear 减 max-blur 分离度均为负。典型情况: 全图中颊部边缘清晰导致 S 偏高而舌面已虚焦; ROI 可缓解但无法消除重叠, 因苔质纹理在轻度散焦下仍具高 Laplacian 能量。

B3 与 B2 路由差距. MobileNetV3-Small 在 ROI 上训练后验证准确率 98.3%, 但在 Edge-IQA 标定的 $\tau=0.465$ 下 B3 的 M2 为 0.829, 低于 B2 的 1.000。学习概率与可解释 Q_{img} 标度不一致; 若对 B3 单独重标定 τ 可缩小差距, 但引入第二套阈值工件。故 B2 仍为首选部署路径, B3 作为可选学习对比。

合成模糊与临床运动. 验证模糊为高斯核 $r \in [2.5, 5.0]$, 真实微动为方向性拖影; Spearman ρ 约 0.36-0.47 反映域差距。

缺框回退. 部分训练图无 COCO 标注时 ROI 回退全图; 标定元数据记录 n_with_bbox。

延迟离群. B3 CPU 推理增加每帧耗时; 表 II 中 B3 p95 RTT 相对 B2 上升与更重评分一致。

操作缓解. 重复 resample_edge 时检查 JSONL flags, 联合 blur+poor_exposure 时优先调光。

审计重放. Edge-IQA 确定性使任意 JSONL 行可用 compute_q(..., use_roi=True) 离线复核路由。

小结. ROI 聚焦解剖区; B3 可学习模糊排序但需独立 τ 方能匹配 B2 路由表现; 重叠与合成模糊仍是主要残余风险。

6.8 算例: 单帧经 B2 路由

设测试图经 ROI 裁剪后 Edge-IQA 得 $Q_{img}=0.53$, $\tau=0.465$, 首次即通过。同图经 $r=3.2$ 模糊后 $Q_{img}=0.38$, flags=[blur], LangGraph 选 resample_edge; 在 $K=2$ 与建模 uplift 下, 多数 Monte Carlo 重试可跨 τ , 与 B2 聚合 M2=1.00 一致。

B3 同帧对比. 学习分数在清晰 ROI 上 $P(\text{clear}) \approx 0.91$, 模糊 ROI 上 ≈ 0.42 (示意)。共享 τ 时模糊帧或仍失败, 解释 B3 M2 低于 B2。

JSONL 片段 (示意).

```
{"q_img":0.53,"route_decision":"upload_cloud"}
{"q_img":0.41,"flags":["blur"],
 "route_decision":"resample_edge"}
```

与 B0 对比. B0 对模糊帧仍上云且 valid=0, 拉低 M2 至 0.56。

操作员提示。 blur 可映射为「请保持静止，系统将自动重拍」。

小结。 本算例连接微观分数与表 II 宏观指标，无需真实 FR3 硬件。

7 单栏参考表

Table 15: 多种子表 II 完整分解 ($\tau=0.465$)。

Seed	基线	M1 p50	M1 p95	M2	M3
0	B0	364.9	659.8	0.568	0.000
0	B2	347.9	573.0	1.000	0.432
0	B3	305.1	622.5	0.824	0.474
1	B2	343.2	571.3	1.000	0.444
1	B3	312.9	619.1	0.840	0.480
2	B2	354.4	574.5	1.000	0.444
2	B3	324.9	607.0	0.824	0.488

Table 16: 工件路径索引。

工件	路径
划分 JSON	experiments/splits/tcm_*.json
τ	recommended_tau.json
ROI 消融	roi_ablation.json
B3 权重	b3_mobilenet.pt
表 II	table_ii.json

复现命令摘要。 `paper1_run_tcm_full.sh` 一键执行；单步见 `REPRODUCE.md`。

学习手册。 中文六章见 `docs-zh/paper1/study/`。

版本。 2026-05-30: ROI + 真实 B3。

局限。 合成模糊；B3/ τ 标度；M6 不混表 II。

Closing。 单栏表便于印刷版快速查阅数字，与正文双栏叙述互补。

8 结论

9 结论

本文在 Franka ROS 2 栈上提出 Edge-IQA 与 Lang-Graph 置信度感知路由，并在公开 ShezhenV3-COCO 语料 (6,719 张) 上完成端到端验证。IQA 与路由置于 1kHz 控制回路之外，兼顾实时安全与 JSONL 可审计闭环。在测试集真实 Edge-IQA 分数上，B2 相对朴素上云改善中位 RTT 与有效帧率； τ 消融与验证集标定 ($\tau=0.498$, M5 $\rho=0.47$) 刻画真实舌象纹理下的工作点。

局限。 验证集模糊为合成注入；真实机器人运动剖面可能不同。真实图像上清晰/模糊组重叠表明 ROI 裁剪或学习 refinement 仍有空间 (B3 仅以仿真加成探索)。云端视觉与 EMR 仍为占位；M6 验证执行栈可行性，不替代离线 RTT 统计。

未来工作。 舌体框条件化打分、Gazebo 相机注入、训练集微调 B3 (冻结主表协议) 及多中心临床采集研究。

References

- [1] S. Chitta, I. Sucan, and S. Cousins. Moveit! In *IEEE Robotics Automation Magazine*, volume 19, pages 18–19, 2012.
- [2] Y. Kang, J. Hu, S. Gummadi, et al. Neurosurgeon: collaborative intelligence between the cloud and mobile edge. In *ACM SIGARCH Computer Architecture News*, volume 45, pages 615–629, 2017.

- [3] E. Li, Z. Zhou, and X. Chen. Edge intelligence: on-demand deep learning model co-inference with device-edge synergy. *ACM Workshop on Mobile Computing Systems and Applications*, 2018.
- [4] S. Macenski, T. Foote, B. Gerkey, et al. Robot operating system 2: design, architecture, and uses in the wild. *Science Robotics*, 7(66):eabm6074, 2022.
- [5] A. Mittal, R. Soundararajan, and A. C. Bovik. Making a completely blind image quality analyzer. In *IEEE Signal Processing Letters*, volume 20, pages 209–212, 2013.
- [6] D. Qi, D. Zhang, and Y. Liu. Tongue image analysis for disease diagnosis. *Pattern Recognition*, 55:1–12, 2016.
- [7] W. Zhang, K. Ma, J. Yan, Z. Deng, and Z. Wang. Blind image quality assessment using a deep bilinear convolutional neural network. *IEEE Transactions on Circuits and Systems for Video Technology*, 30(1):36–47, 2020.
- [8] X. Zhang, Y. Wang, and H. Liu. Automatic tongue diagnosis: a survey. *Artificial Intelligence Review*, 53(5):3145–3187, 2020.

A 补充材料

一键复现。 仓库根目录执行 `bash scripts/paper1_run_tcm_full.sh`: 导入划分、训练 B3、ROI 标定 τ 、主矩阵 (3 seeds)、图表与 PDF。

工件清单。

- `tcm_{train,val,test}.json` — 6719 张，含 COCO bboxes；
- `recommended_tau.json` — ROI 标定 ($n=1144$)；
- `roi_ablation.json` — 全图 vs 舌区 ROI；
- `b3_mobilenet.pt, b3_training_meta.json` — B3 权重与验证准确率；
- `calibration_val.csv, main_seed*_detail.csv` — 分数与帧级日志。

环境. Edge-IQA 仅需 NumPy/Pillow; B3 训练使用 doctor/paper1/.venv (PyTorch)。WSL 下数据集路径见 tcm_paths.yaml。

超参数. Edge-IQA: 512 缩放, 0.65/0.35 权重; ROI 8% padding。B3: MobileNetV3-Small, 224 输入, AdamW 10^{-3} , 5 epoch, batch 64。路由: τ 来自验证集中位数, $K=2$ 。

JSONL 十字段. trial_id、image_path、q_img、flags、retry_count、route_decision、latency_ms、t_capture、t_iqa、t_route。

局限. 合成高斯模糊; 运行时需框或检测器; B3 与 Edge-IQA 的 τ 标度不一致; M6 不与表 II 直接对比。

伦理. 使用公开 ShezhenV3-COCO; JSONL 不含患者标识。

未来工作. 端侧舌检测 ROI; 混合 Edge-IQA+B3 头; 自 FR3 日志采集运动模糊 augment。

表 S1: ROI 消融 (摘要). 全图 $\tau=0.498$, ROI $\tau=0.465$; 详见 roi_ablation.json。

表 S2: B3 训练 (摘要). 5594 训练图, 11188 对, 验证准确率 98.3%。

Listing S2: 标定命令. python3 experiments/edge_iqa/calibrate_tau_tcm.py

Listing S3: B3 训练命令. .venv/bin/python experiments/edge_iqa/train_b3_mobilenet.py

Listing S4: 主矩阵. .venv/bin/python experiments/run_matrix_tcm.py

版本记录. 2026-05-30: ROI + 真实 B3 + ShezhenV3 全量验证纳入正文。

联系维护. 算法问题见 docs-zh/paper1/study/学习手册六章。

许可. 代码 Apache-2.0; ShezhenV3 遵循其公开许可。

图 S1. M6 Franka RTT 直方图 见 fig_s1_franka_rtt.pdf。

扩展阅读. V19 大纲 docs-zh/paper1/V19/; 网关 ENV docs-zh/paper1/V19/ENV.md。

故障排查. 若 b3_mobilenet.pt 缺失, 主矩阵 B3 回退 b3_q_boost (已默认关闭 b3_use_learned)。

性能提示. B3 训练在 CPU 上约 45 分钟 (5594 图 $\times$ 5 epoch); 可减小 --max-train 做 smoke test。

中文稿说明. 本中文稿与英文稿章节同步; 表 II 由 sync_table_ii_zh.py 自动生成。

致谢占位. 相机就绪版补充基金与临床合作单位。

数据不包含项. 投稿包不含原始患者图像, 仅含统计与脚本。

安全提示. 生产环境务必配置 FRANKA_API_KEY。

Closing. 补充材料旨在使审稿人与学生可在无 FR3 硬件条件下复现 Table II 与标定数字。

B 扩展算法与表格

Algorithm 3 COCO ROI 裁剪 (并集 + padding)

输入: 图像 I , 框集合 $\{b_j = [x, y, w, h]\}$, padding p $B \leftarrow$ 所有框的并集各边按 p 比例外扩并裁剪至图像边界 $\text{crop}(I, B)$

Table 17: B3 训练超参数 (ShezhenV3 train)。

超参数	取值
结构	MobileNetV3-Small (ImageNet 初始化)
输入	224×224
优化器	AdamW, 10^{-3} , wd 10^{-4}
Batch	64
Epoch	5
训练对	11,188
验证准确率	98.34%

多种子表 II. Seed 0--2 上 B2 M2 均为 1.00; B3 M2 约 0.82--0.84。

导入统计. Train 5594 / val 572 / test 553; 5404 张训练图含框。

Table 18: 延迟模型分量 (毫秒)。

分量	取值
采集	5.0
Edge-IQA	$\mathcal{N}(9, 2^2)$
路由	1.5
重采	p50 $\approx$ 50
上云	$\mathcal{U}(50, 550)$
B3 额外	+15-40 (CPU 量级)

术语. M1 端到端 RTT; M2 有效上传率; M3 重采率; M5 Spearman 相关。

网关环境变量. 见 docs-zh/paper1/V19/ENV.md。

扩展阅读. 学习手册 docs-zh/paper1/study/ 六章; 复现 REPRODUCE.md。

版本. 2026-05-30: ROI + 真实 B3 纳入附录与正文。

校验. 提交前对 b3_mobilenet.pt 记录 SHA256。

图算法说明. LangGraph 三支与正文 Algorithm 2 一致; JSONL 字段见补充材料。

数据伦理. 公开数据集离线使用; 不写入患者标识。

性能. 全矩阵 CPU 约 10 分钟 (不含 B3 训练); B3 训练约 45 分钟。

故障排查. 缺权重时检查 b3_use_learned 与 .venv PyTorch 安装。

Closing. 本附录支撑审稿人快速核对超参与延迟假设, 无需阅读全部源码。